TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
HCM·UTE
HCMC University of Technology and Engineering

[BDES333877] Nhập Môn Dữ Liệu Lớn

CHƯƠNG 02: CÁC KỸ THUẬT LƯU TRỮ VÀ XỬ LÝ DỮ LIỆU LỚN

ThS. Lê Thị Minh Châu

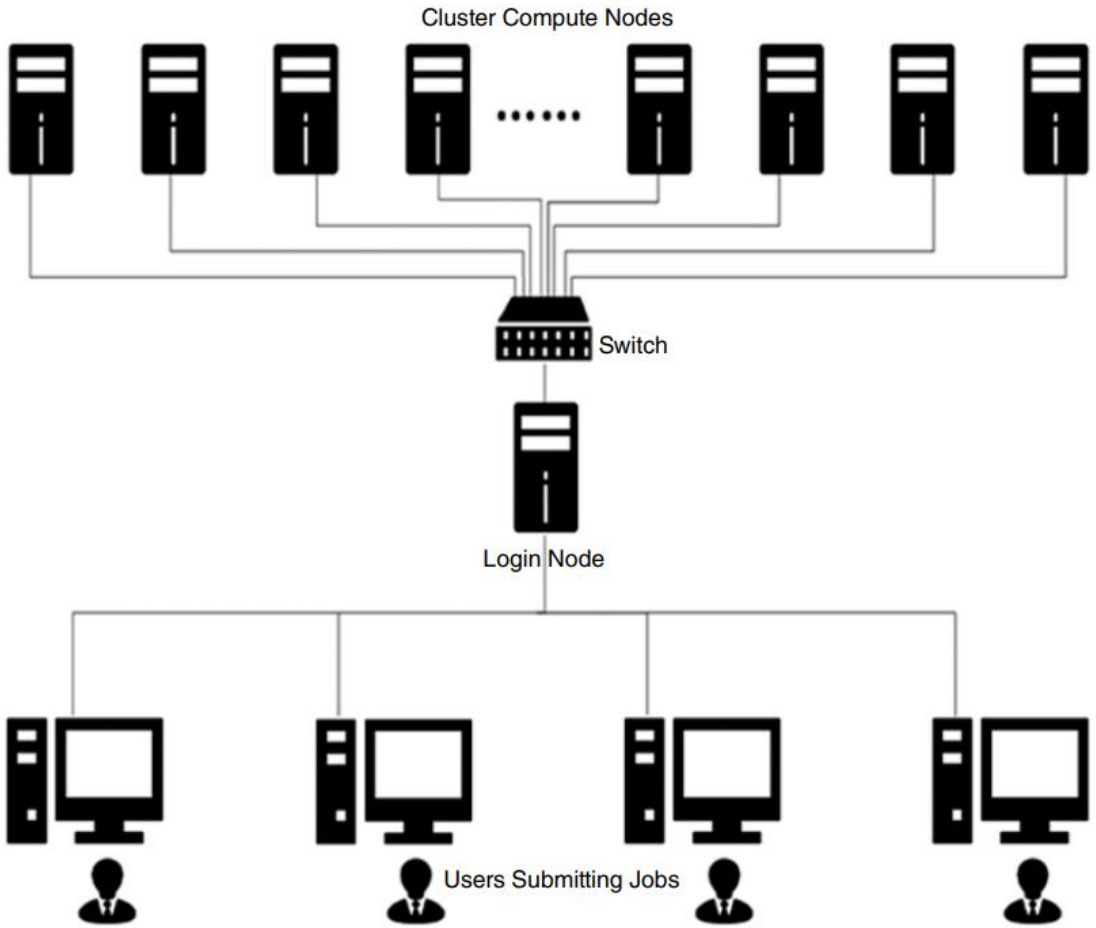
Nội dung của bài học

1. Đặt vấn đề
2. Điện toán cụm
3. Các mô hình phân tán
4. Hệ thống tập tin phân tán
5. Cách thức mở rộng hệ thống
6. Các kỹ thuật xử lý dữ liệu lớn
7. Dữ liệu lớn và điện toán đám mây
8. Tổng kết
9. Bài tập

- Làm sao lưu trữ và xử lý Dữ Liệu Lớn?
- Các kiến trúc truyền thống có đảm bảo lưu trữ và xử lý được Dữ Liệu Lớn?
- Các hệ thống lưu trữ và xử lý Dữ Liệu Lớn hoạt động như thế nào?

- **Điện toán cụm (Cluster Computing)**
  - **Điện toán cụm là một hệ thống tính toán phân tán hoặc song song bao gồm nhiều máy tính cá nhân độc lập được kết nối với nhau thông qua mạng LAN và hoạt động như một tài nguyên duy nhất, tích hợp và có tính sẵn sàng cao, hiệu suất có thể mở rộng, cân bằng tải, khả năng chịu lỗi và sử dụng phần cứng thương mại (commodity hardware) hiệu quả về chi phí.**
  - **Mỗi tài nguyên máy tính có thể chạy một phiên bản hệ điều hành.**
  - **Một cụm các hệ thống có thể kết nối với một nhóm các hệ thống để chia sẻ các tác vụ tính toán quan trọng.**
  - **Khả năng mở rộng đạt được bằng cách loại bỏ hoặc bổ sung thêm các Node (node) theo yêu cầu mà không cản trở hoạt động của hệ thống.**

- **Điện toán cụm (Cluster Computing)**
  - Các máy chủ trong điện toán cụm được gọi là các node. Điện toán cụm có thể theo kiến trúc khách – chủ (Client – Server) hoặc mô hình ngang hàng (Peer-to-Peer).
  - Điện toán cụm cung cấp khả năng tính toán tốc độ cao để xử lý các ứng dụng chuyên sâu về dữ liệu liên quan đến công nghệ dữ liệu lớn.
  - Các cụm có khả năng thay đổi kích thước tự động, co giãn khi bất kỳ máy chủ nào ngưng hoạt động hoặc tăng kích thước khi các máy chủ tăng cường được thêm vào để xử lý nhiều tải trọng hơn.
  - Điện toán cụm vẫn có thể hoạt động hoặc bị tác động rất ít khi hệ thống xảy ra lỗi. Các cụm áp dụng cơ chế chuyển đổi dự phòng để loại bỏ các dịch vụ bị gián đoạn. Chuyển đổi dự phòng là một cơ chế tự động không cần bất kỳ sự can thiệp nào của con người.



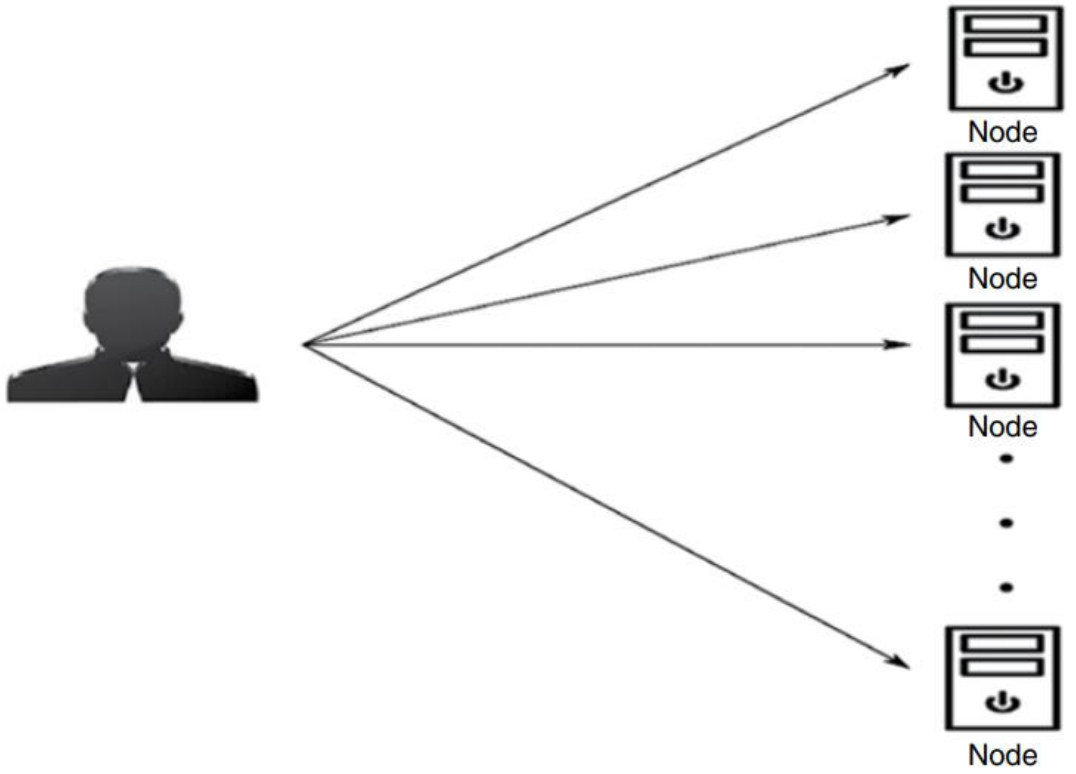
Hình 1: Kiến trúc Điện toán cụm

- **Cụm có tính sẵn sàng cao**
  - Các cụm có tính sẵn sàng cao được thiết kế để giảm thiểu thời gian chết và cung cấp dịch vụ không bị gián đoạn khi các node bị lỗi. Cụm thường được dùng cho các mục đích chuyển đổi dự phòng và sao lưu.
  - Nếu một node không hoạt động, dịch vụ vẫn tiếp tục được cung cấp do chuyển dịch vụ từ node lỗi sang node khác trong điện toán cụm mà không cần sự can thiệp của quản trị viên. Khi chuyển dịch vụ từ node này sang node khác, các cụm phải đảm bảo duy trì tính toàn vẹn của dữ liệu.
  - Hệ thống có tính sẵn sàng cao giúp loại trừ điểm lỗi duy nhất (Single Point of Failure).
  - Các hệ thống có tính sẵn sàng cao cần thiết cho các doanh nghiệp chống lại việc mất dữ liệu giao dịch hoặc dữ liệu không đầy đủ và khắc phục nguy cơ ngừng hoạt động của hệ thống. Hệ thống thanh toán, ngân hàng, thương mại điện tử yêu cầu một hệ thống có tính sẵn sàng cao mà không làm mất dữ liệu giao dịch.

- **Cụm cân bằng tải**
  - Các cụm cân bằng tải được thiết kế để phân phối khối lượng công việc trên các node khác nhau trong cụm để chia sẻ tải trọng dịch vụ giữa các node. Nếu một node trong cụm cân bằng tải gặp sự cố, tải trọng từ node đó sẽ được chuyển sang node khác. Điều này đạt được bằng cách lưu trữ các bản sao giống nhau trên tất cả các node.
  - Mục tiêu chính của cân bằng tải là tối ưu hóa việc sử dụng tài nguyên, rút ngắn thời gian đáp ứng, tối đa hóa thông lượng và tránh quá tải trên bất kỳ tài nguyên nào.
  - Các tài nguyên có nhiều quyền kiểm soát đối với cách thức mà các yêu cầu (request) được định tuyến (route). Loại định tuyến này là cần thiết khi một cụm bao gồm các máy hoạt động không hiệu quả như nhau. Thay vì chỉ có một máy chủ duy nhất, rất đắt tiền và rất mạnh, cân bằng tải có thể được sử dụng để chia sẻ tải trọng trên một số hệ thống có hệ suất thấp, rẻ tiền để có khả năng mở rộng tốt hơn.

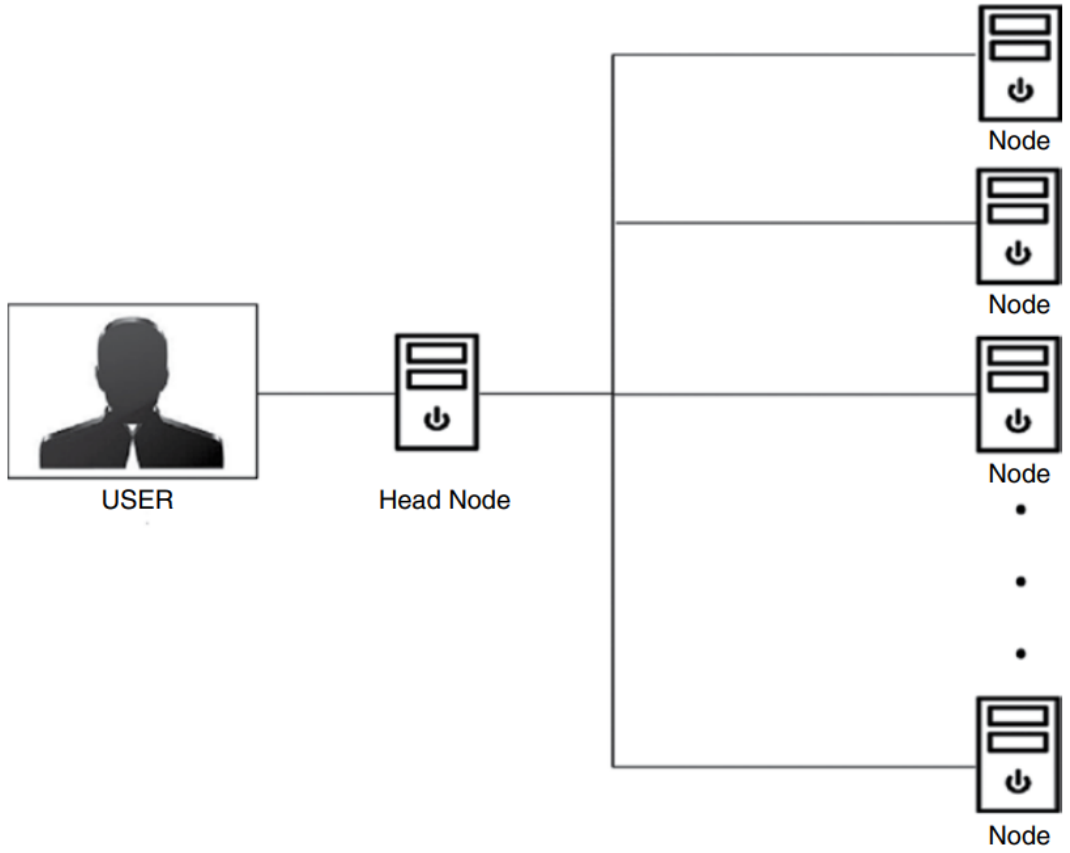
- **Cân bằng tải Round Robin**
  - Chọn các máy chủ từ máy chủ trên cùng trong danh sách theo thứ tự tuần tự cho đến khi máy chủ cuối cùng trong danh sách được chọn. Sau khi máy chủ cuối cùng được chọn, nó sẽ trở lại đầu danh sách.
- **Cân bằng tải dựa trên trọng lượng**
  - Các máy chủ sẽ được gán một trọng số có giá trị từ 1 đến 100, xác định tỷ trọng tải mà máy chủ có thể chịu được so với các máy chủ khác. Nếu các máy chủ chịu được tỷ trọng như nhau, tỷ trọng tải bằng nhau sẽ được phân phối giữa các máy chủ.
- **Cân bằng tải ngẫu nhiên**
  - Định tuyến các yêu cầu đến máy chủ một cách ngẫu nhiên. Cân bằng tải ngẫu nhiên chỉ thích hợp cho các cụm đồng nhất khi các máy được cấu hình tượng tự nhau.
- **Cân bằng tải mối quan hệ máy chủ**
  - Ghi nhớ máy chủ nơi máy khách khởi tạo yêu cầu và định tuyến các yêu cầu tiếp theo đến cùng một máy chủ.

- **Cụm đối xứng**
  - Là kiểu cấu trúc cụm trong đó mỗi node hoạt động như một máy tính riêng lẻ có khả năng chạy các ứng dụng. Việc thiết lập các cụm đối xứng rất đơn giản và dễ hiểu. Một mạng con được tạo ra với các máy riêng lẻ hoặc các máy có thể được thêm vào mạng hiện có và các phần mềm dành riêng cho cụm có thể được cài đặt trên các máy. Có thể bổ sung thêm các máy khi cần thiết.

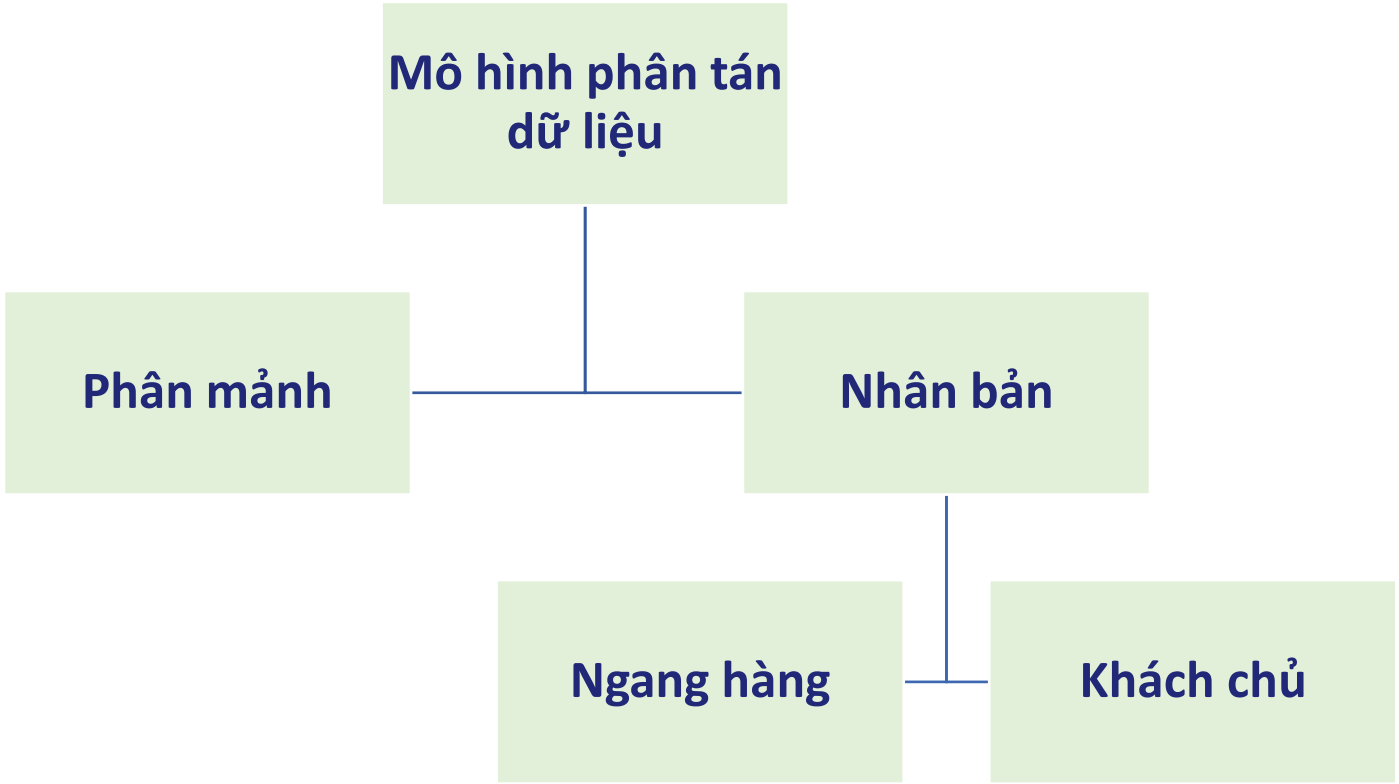


Hình 2: Kiến trúc cụm đối xứng

- **Cụm bất đối xứng**
  - Là loại cấu trúc cụm trong đó một máy hoạt động như một node dẫn đầu và đóng vai trò là cổng kết nối giữa người dùng và các node còn lại.

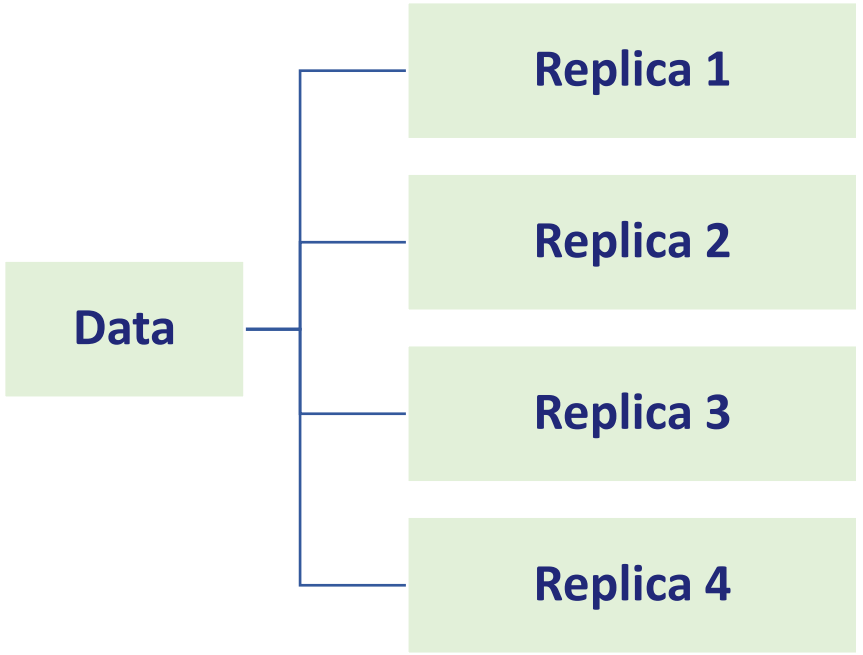


Hình 3: Kiến trúc cụm bất đối xứng



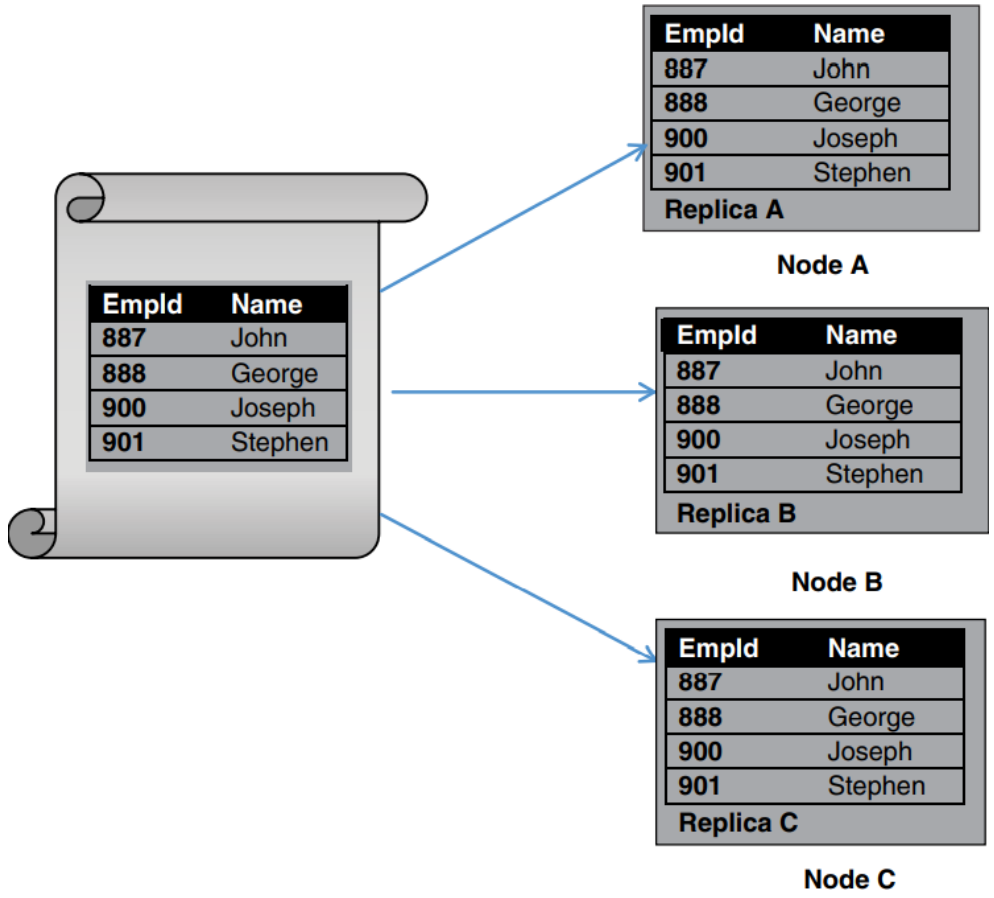
Hình 4: Các kỹ thuật phân tán dữ liệu

- **Nhân bản (Replication)**
  - Nhân bản là quá trình tạo ra các bản sao của cùng một tập dữ liệu trên nhiều máy chủ. Khi một node gặp sự cố, dữ liệu lưu trữ trong node đó sẽ bị mất. Ngoài ra, khi một node ngừng hoạt động để bảo trì, node đó sẽ không sẵn sàng cho đến khi quá trình bảo trì kết thúc. Để khắc phục những vấn đề này, khối dữ liệu được sao chép qua nhiều node. Quá trình này được gọi là nhân bản dữ liệu (Data Replication) và khối dữ liệu được sao chép gọi là bản sao (Replica).



Hình 5a: Kỹ thuật nhân bản dữ liệu

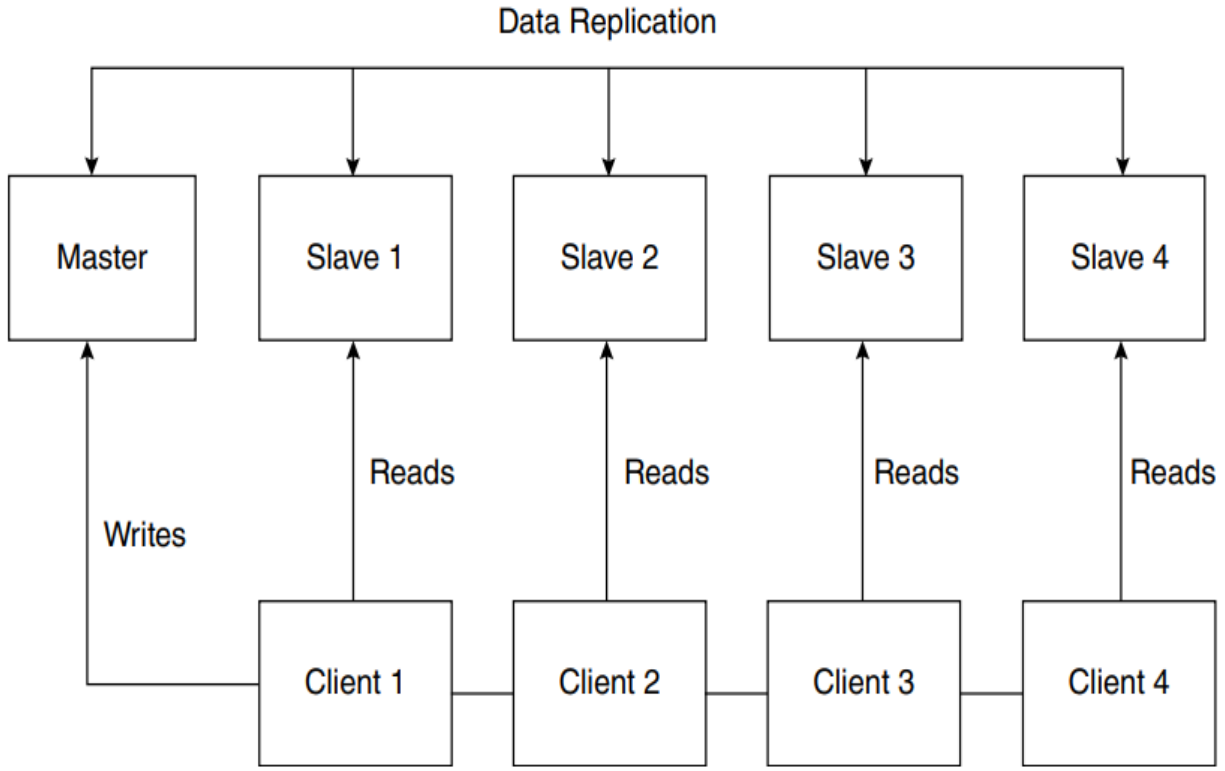
- **Nhân bản (Replication)**
  - Nhân bản dữ liệu giúp hệ thống có khả năng chịu lỗi vì dữ liệu không bị mất khi một node riêng lẻ bị lỗi vì dữ liệu đã được dự phòng trên các node. Nhân bản làm tăng tính sẵn sàng của dữ liệu vì cùng một bản sao của dữ liệu có sẵn trên nhiều node.
  - Hình 5b minh họa cùng một tập dữ liệu được nhân bản trên các node A, node B, node C. Nhân bản dữ liệu có thể thực hiện trên các mô hình chủ - tớ (master – slave) và mô hình ngang hàng (peer – to – peer).
  - Nhân bản và phân mảnh có thể được sử dụng độc lập hoặc chung với nhau.



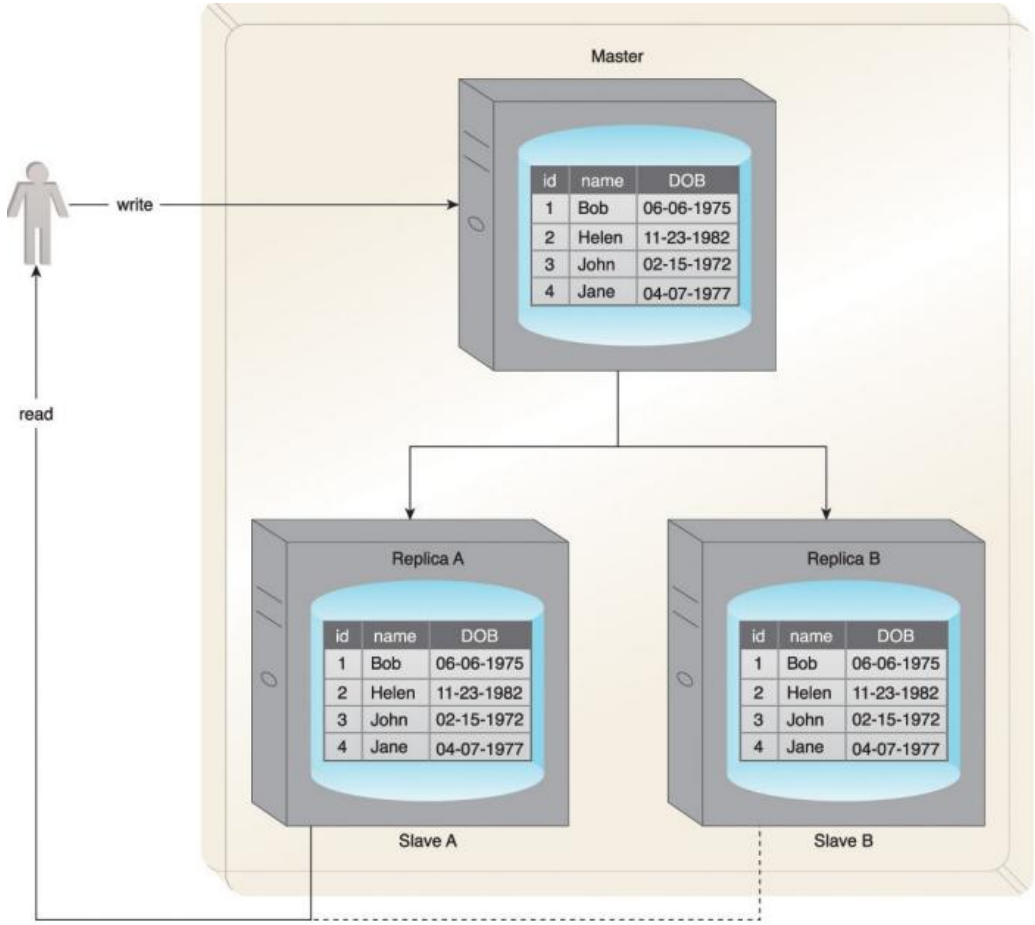
Hình 5b: Nhân bản dữ liệu trên các node

Mô hình master - slave

- Trong nhân bản master – slave, một thiết bị trung tâm được gọi là thiết bị master điều khiển một hoặc nhiều thiết bị slave.
- Một tập các bản sao tạo thành một node master và nhiều node slave. Khi kết nối giữa master và slave được thiết lập, luồng điều khiển chỉ đi từ máy master sang các máy slave.
- Tất cả dữ liệu đến được ghi trên node master và cùng một dữ liệu được sao chép qua nhiều máy slave. Tất cả yêu cầu ghi được xử lý bởi node master và các thao tác cập nhật, thêm và xóa dữ liệu xảy ra trong node master, trong khi các yêu cầu đọc được xử lý bởi các node slave.
- Kiến trúc này hỗ trợ các yêu cầu đọc dữ liệu chuyên sâu vì nhu cầu ngày càng tăng có thể được xử lý bằng cách bổ sung thêm các node slave. Nếu node master bị lỗi, các yêu cầu ghi sẽ không thể thực hiện được cho đến khi node master hoạt động trở lại hoặc một node master mới được tạo ra từ một trong các node slave.



Hình 6a: Nhân bản dữ liệu trên mô hình master - slave



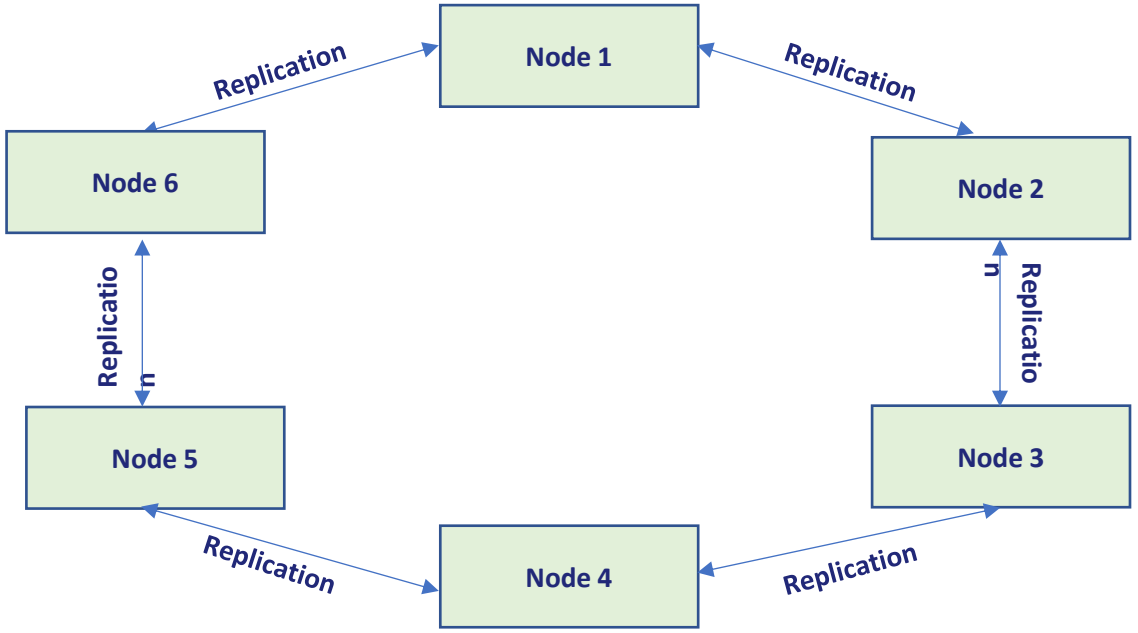
Hình 6b: Đọc/ghi dữ liệu trên các phân mảnh theo mô hình master - slave

Mô hình ngang hàng peer – to – peer

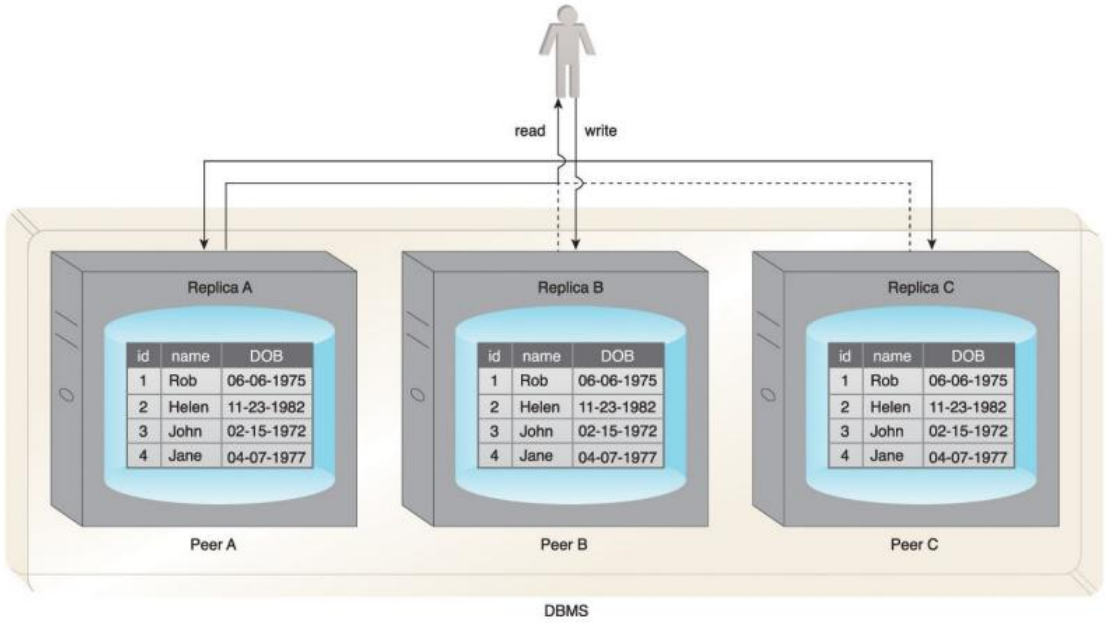
- Trong mô hình master - slave chỉ các máy slaves mới đảm bảo chống lại một điểm thất bại duy nhất (single point of failure). Cụm vẫn bị một điểm thất bại duy nhất nếu máy master bị lỗi. Ngoài ra, việc ghi dữ liệu bị giới hạn ở khả năng tối đa mà máy master có thể xử lý, do đó mô hình này chỉ cung cấp khả năng mở rộng đọc dữ liệu.
- Trong mô hình peer – To – peer không có khái niệm chủ tớ, tất cả các node đều có trách nhiệm như nhau và ở cùng một cấp độ. Các node trong cấu hình peer – to – peer hoạt động như máy khách (client) và máy chủ (server). Trong mô hình master – slave, kết nối luôn được khởi tạo bởi máy master trong khi ở cấu hình ngang hàng, một trong các thiết bị tham gia vào tiến trình có thể khởi tạo kết nối. Mỗi node được gọi là một peer, có khả năng xử lý đọc và ghi như nhau.

Mô hình ngang hàng peer – to – peer

- Trong mô hình peer – to – peer, khối lượng công việc hoặc tác vụ được phân chia giữa các node. Các node sử dụng tài nguyên và cũng đóng góp tài nguyên cho hệ thống. Các tài nguyên như không gian lưu trữ đĩa, bộ nhớ, băng thông, năng lực xử lý được chia sẻ giữa các node.
- Độ tin cậy của mô hình này được cải tiến thông qua việc nhân bản. Ngoài ra, các node được kết nối trong cấu hình peer – to – peer được phân bố theo địa lý trên toàn cầu.



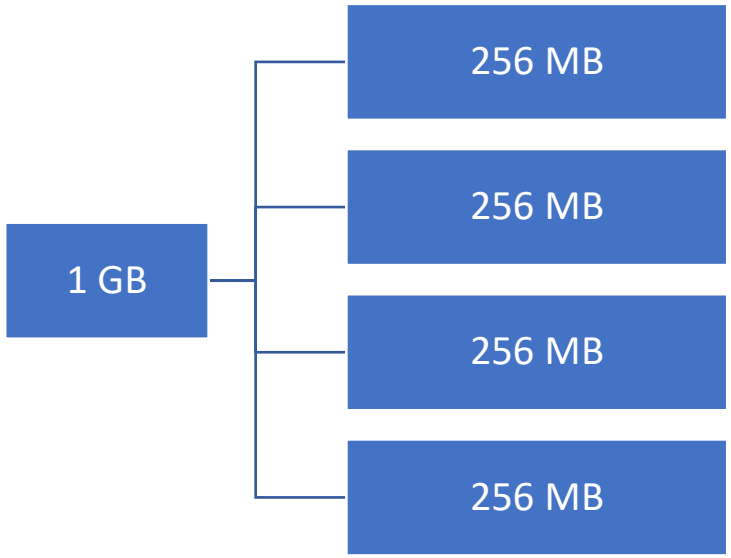
Hình 7a: Nhân bản dữ liệu trên mô hình peer – to – peer



Hình 7b: Đọc/ghi dữ liệu trên mô hình peer – to – peer

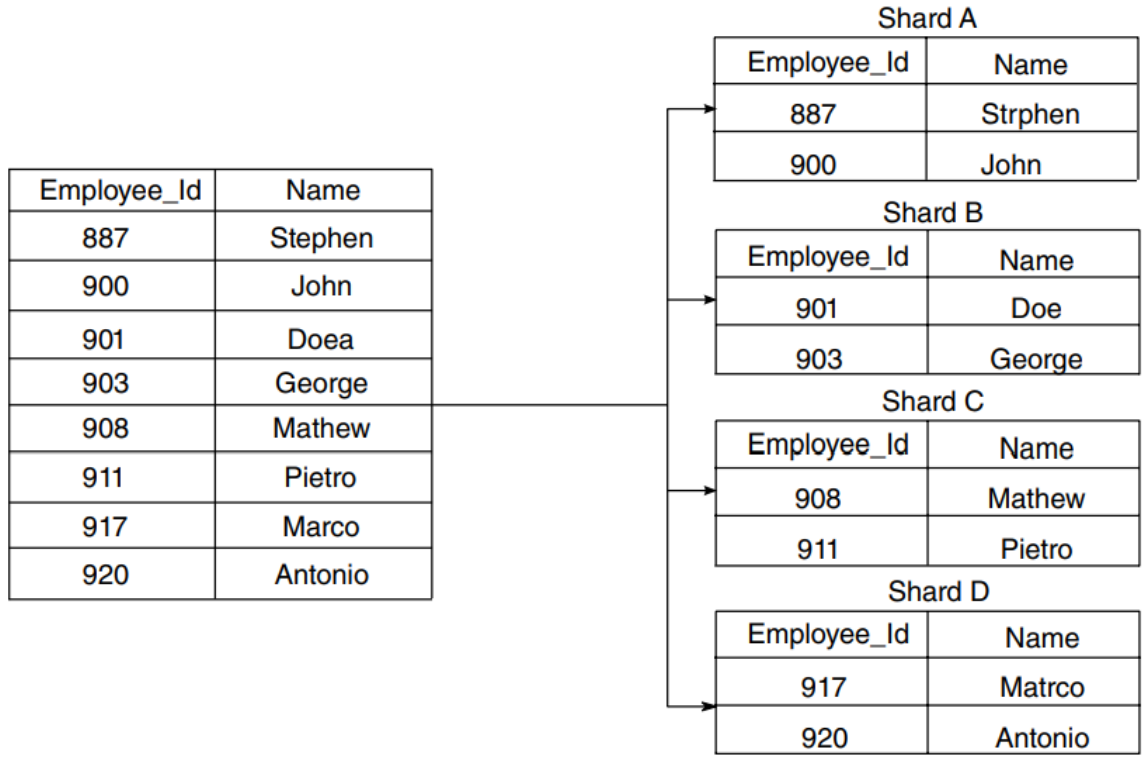
- **Phân mảnh (Sharding)**
  - Phân mảnh là quá trình phân chia các tập dữ liệu rất lớn thành các thành phần nhỏ hơn và dễ quản lý gọi là các mảnh (shard).
  - Các mảnh phân đoạn được lưu trữ bằng cách phân tán chúng trên nhiều máy được gọi là các node.
  - Không có hai phân đoạn nào của cùng một tập tin được lưu trữ trong cùng một node. Mỗi phân đoạn trên một node riêng biệt.
  - Mỗi phân đoạn chia sẻ cùng một lược đồ và các phân đoạn trải rộng trên nhiều node tổng thể tạo thành một tập dữ liệu hoàn chỉnh.

- **Phân mảnh (Sharding)**
  - Hình 8a cho thấy 01 khối dữ liệu 1 GB được chia thành 04 phần, mỗi phần 256 MB. Khi kích thước của dữ liệu tăng lên, một node duy nhất có thể không đủ để lưu trữ dữ liệu.
  - Với cơ chế phân mảnh, nhiều node hơn được thêm vào để đáp ứng nhu cầu của tốc độ tăng trưởng dữ liệu lớn.
  - Phân mảnh làm giảm số lượng giao dịch mà mỗi node xử lý và làm tăng thông lượng trên mỗi node. Phân mảnh cũng làm giảm dữ liệu mà mỗi node cần lưu trữ.

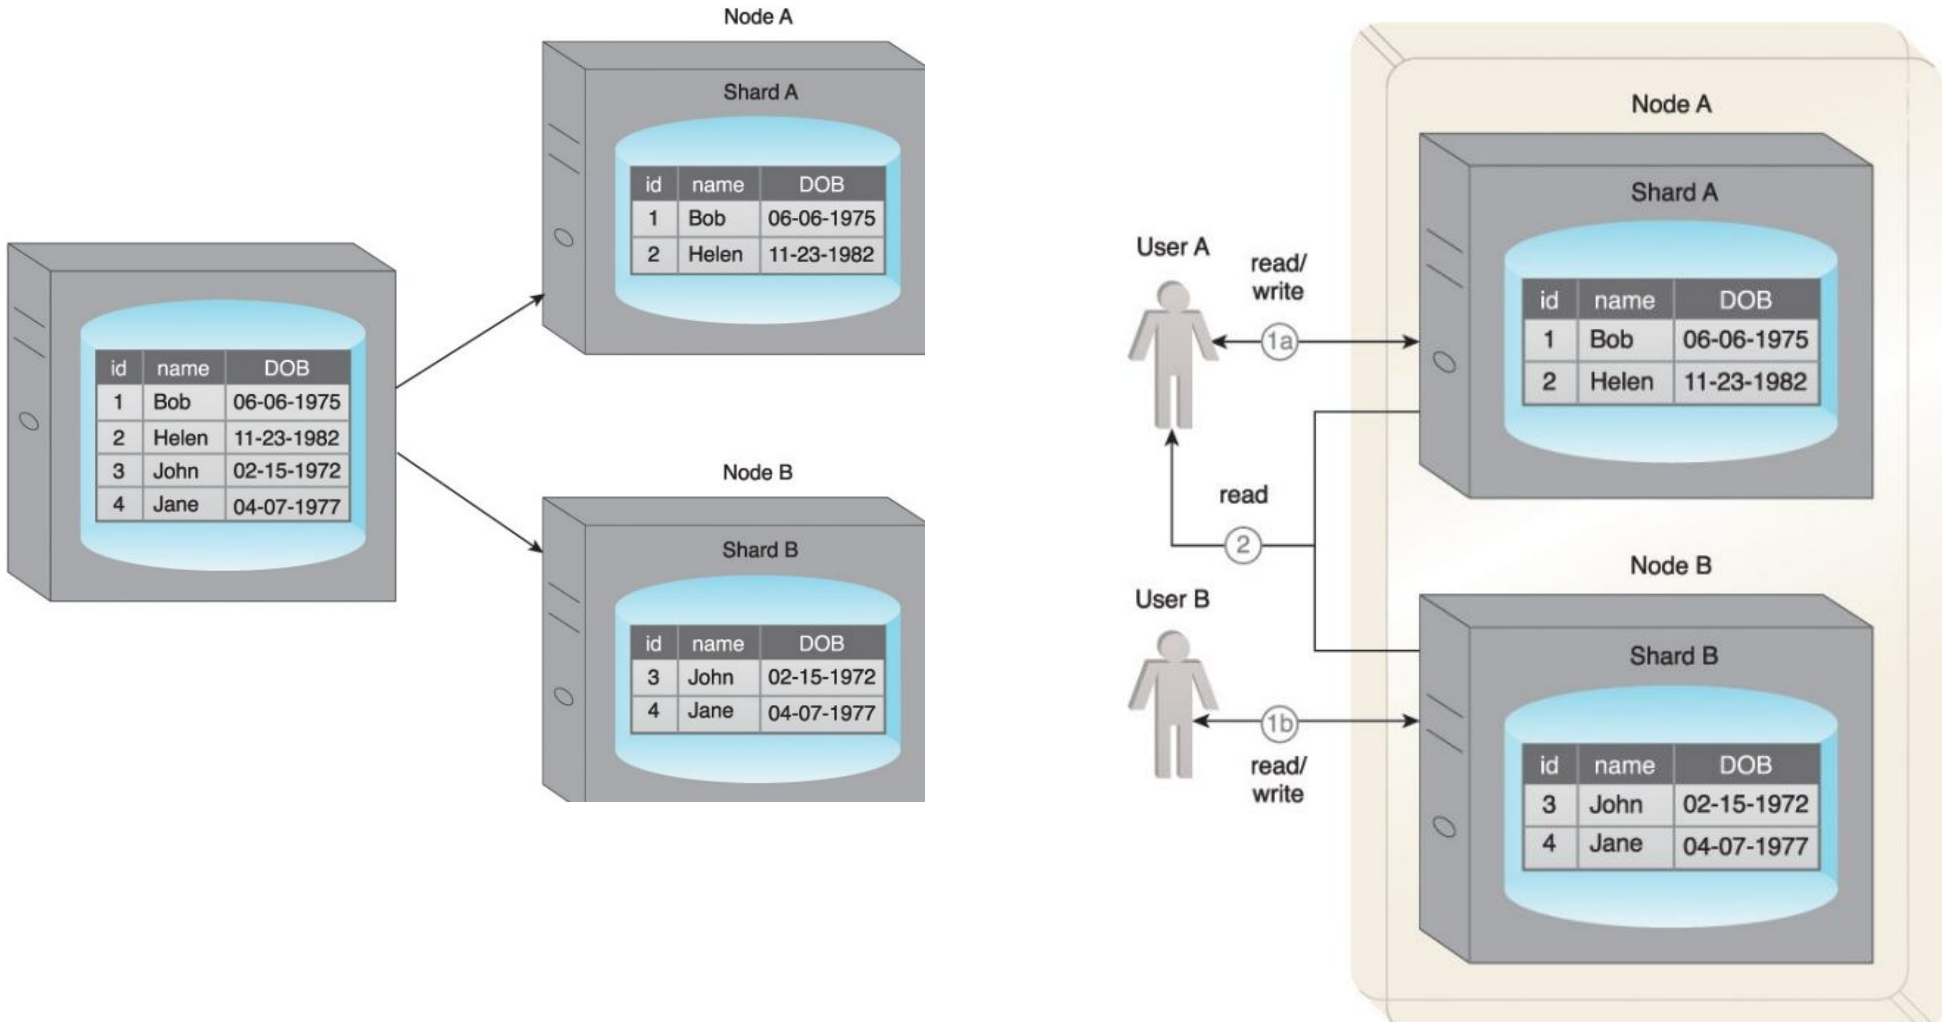


Hình 8a: Kỹ thuật phân mảnh dữ liệu

- **Phân mảnh (Sharding)**
  - Hình 8b là ví dụ một khối dữ liệu chia thành nhiều mảnh trên nhiều node. Tập dữ liệu thông tin nhân viên được chia thành 04 khối nhỏ: mảnh A, mảnh B, mảnh C, mảnh D được lưu trữ trên 04 node khác nhau: node A, node B, node C, node D. Cơ chế phân mảnh cải thiện khả năng chịu lỗi của hệ thống vì lỗi xảy ra trên một node chỉ ảnh hưởng đến dữ liệu được lưu trữ trên node đó.



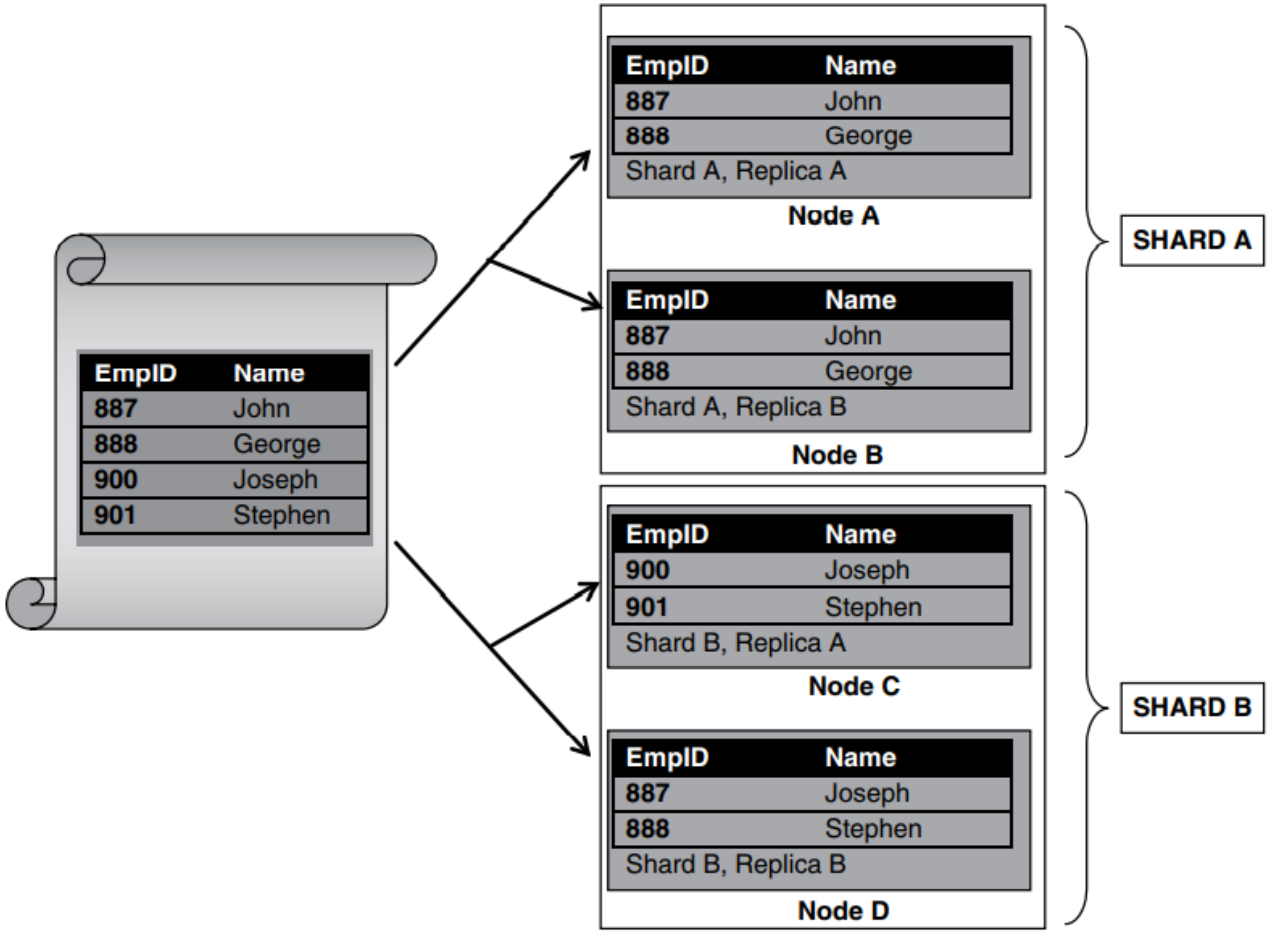
Hình 8b: Phân mảnh dữ liệu



Hình 8c: Ví dụ về Phân mảnh dữ liệu

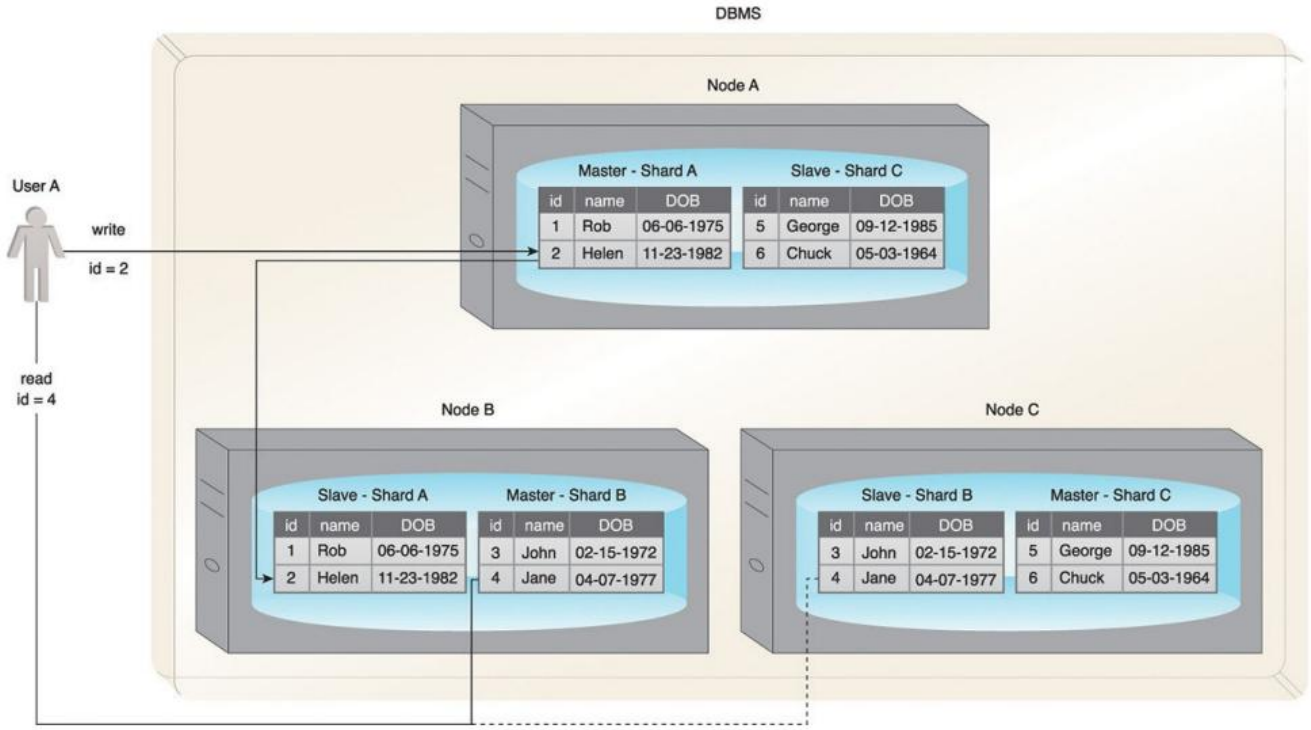
Trong việc nhân bản, khi một node gặp sự cố thì dữ liệu lưu trữ trong node bị mất. Vì vậy, nhân bản chỉ cung cấp khả năng chịu lỗi ở mức giới hạn cho hệ thống. Phân mảnh và nhân bản có thể kết hợp lại để làm tăng khả năng chịu lỗi và tính sẵn sàng cho hệ thống.

Hình 9a minh họa sự kết hợp của cơ chế phân mảnh và nhân bản khi tập dữ liệu được chia thành phân mảnh A, phân mảnh B. Phân mảnh A được nhân bản trên node A và node B, tương tự, phân mảnh B được nhân bản trên node C và D.



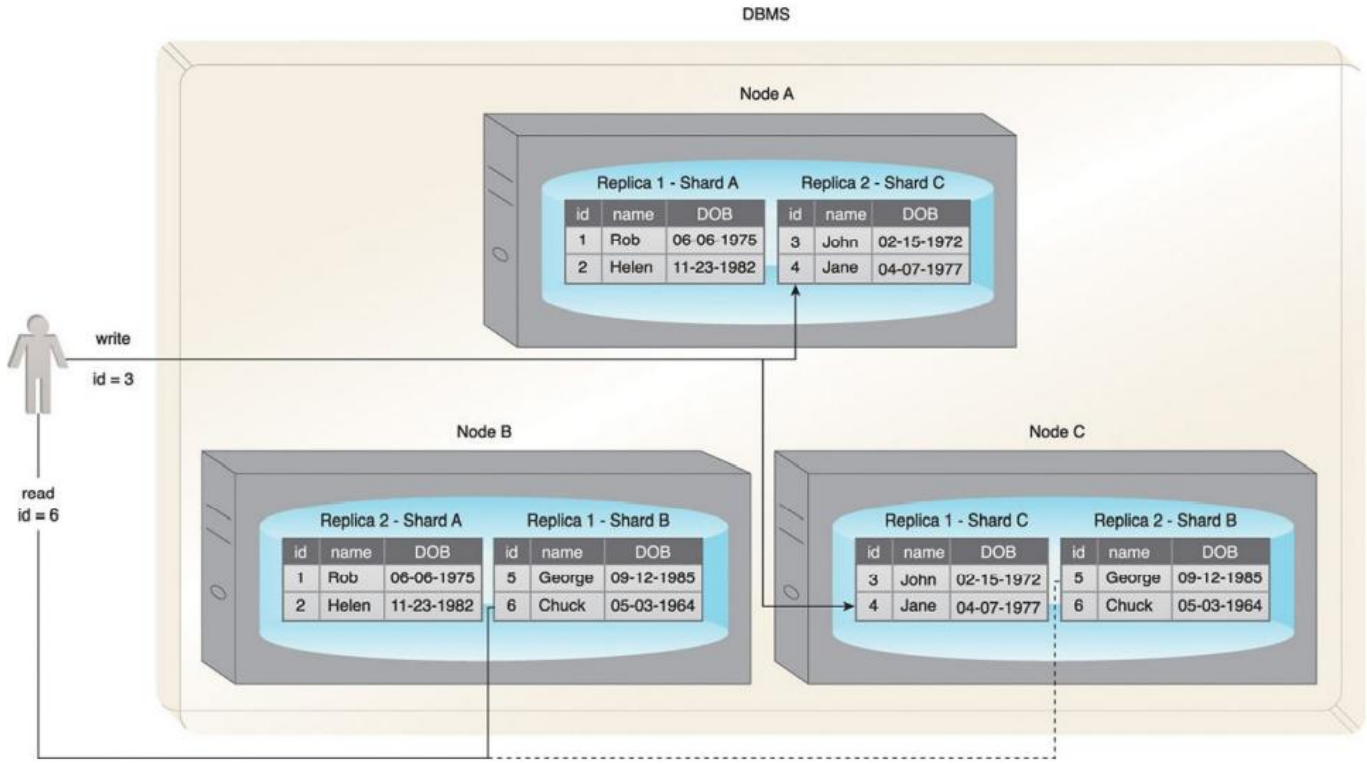
Hình 9a: Kết hợp nhân bản và phân mảnh dữ liệu

- Trong hình 9b, mỗi node đóng vai trò như một máy master và một máy slave cho các phân đoạn khác nhau.
- Việc ghi id = 2 vào Shard A được điều chỉnh bởi node A vì đó là máy master của Shard A.
- Node A nhân bản dữ liệu (id = 2) cho node B, vốn dĩ là máy slave cho Shard A.
- Việc đọc dữ liệu (id = 4) có thể được thực hiện trực tiếp trên node B hay node C vì chúng đều chứa Shard B.



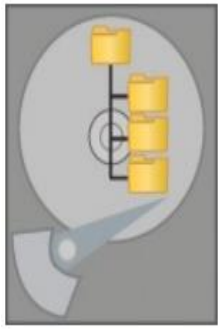
Hình 9b: Kết hợp nhân bản và phân mảnh dữ liệu trên mô hình master - slave

- Trong hình 9c, mỗi node chứa các nhân bản của các shard khác nhau.
- Việc ghi (id = 3) được nhân bản trên cả node A và node C vì chúng chứa shard C.
- Việc đọc (id = 6) có thể được thực hiện trên node B và node C vì chúng chứa Shard B.



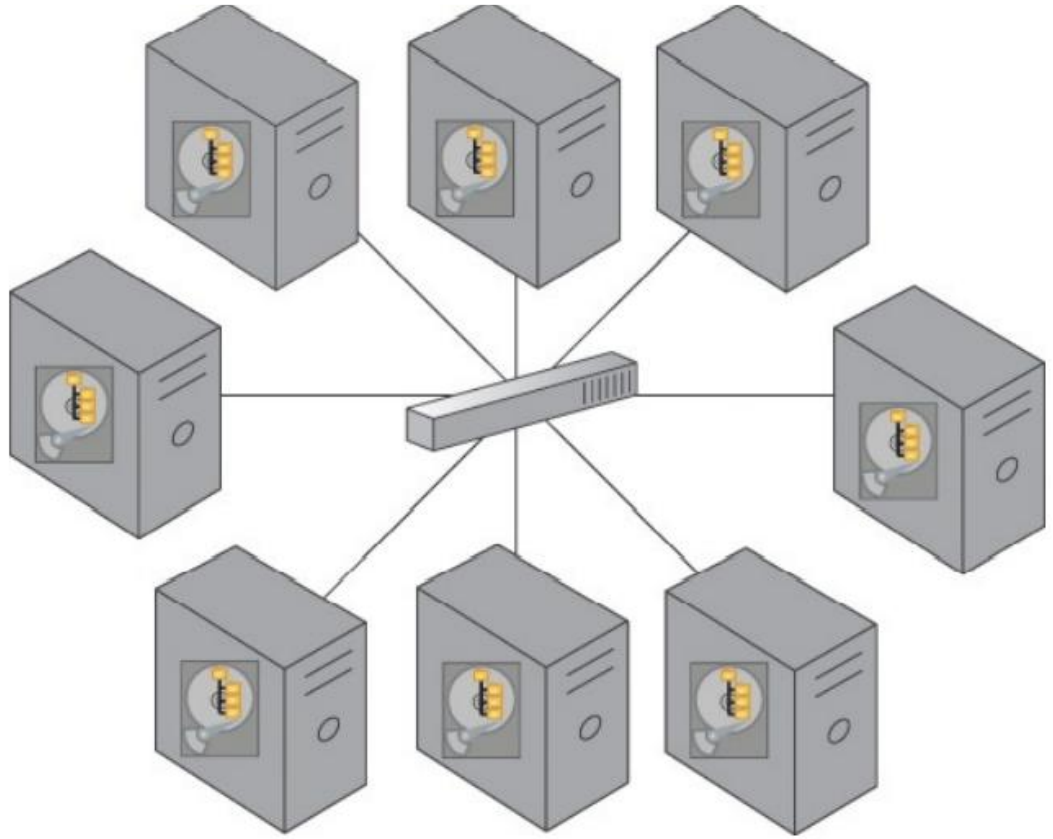
Hình 9c: Kết hợp nhân bản và phân mảnh dữ liệu trên mô hình peer – to – peer

- Tập tin là một đơn vị lưu trữ nguyên tố (atomic) được sử dụng bởi các hệ thống tập tin để lưu trữ dữ liệu.
- Hệ thống tập tin là cách thức tổ chức, lưu trữ dữ liệu trên các thiết bị như ổ cứng, DVD… và quản lý các tập tin được lưu trữ trên đó, giúp cho các chương trình ứng dụng chạy hiệu quả trên các hệ điều hành.
- Hệ thống tập tin cung cấp góc nhìn luận lý (logic) về dữ liệu được lưu trữ trên thiết bị lưu trữ và hiển thị nó dưới dạng cấu trúc cây bao gồm các thư mục chứa các tập tin như trong hình 10.
- Mỗi hệ điều hành sẽ cung cấp các hỗ trợ cho một hoặc nhiều hệ thống tập tin, ví dụ: NTFS trên hệ điều hành Microsoft Windows và EXT trên hệ điều hành Linux.



Hình 10: Biểu tượng biểu diễn hệ thống tập tin

- Hệ thống tập tin phân tán lưu trữ các tập tin trên một cụm các node và cho phép các máy khách truy cập các tập tin từ cụm. Mặc dù về mặt vật lý, các tập tin được phân phối trên các node nhưng về mặt luận lý, các tập tin vẫn xuất hiện trên máy khách như thể đang được lưu trữ cục bộ trong máy.
- Máy chủ có cơ chế tổ chức các bản cập nhật để các máy khách truy cập đồng thời vào phiên bản cập nhật hiện tại của tập tin và không có xung đột phiên bản nào phát sinh.
- Dữ liệu lớn sử dụng hệ thống tập tin phân tán phổ biến là GFS (Google File System) và HDFS (Hadoop Distributed File System).
- Trong hệ thống tập tin phân tán, các bản sao của dữ liệu gọi là các nhân bản (replica) được phân phối trên nhiều node cụm do đó không có điểm lỗi duy nhất (single point of failure).
- Máy khách có thể giao tiếp với bất kỳ node nào có sẵn gần nhất để giảm độ trễ và lưu lượng truy cập mạng.



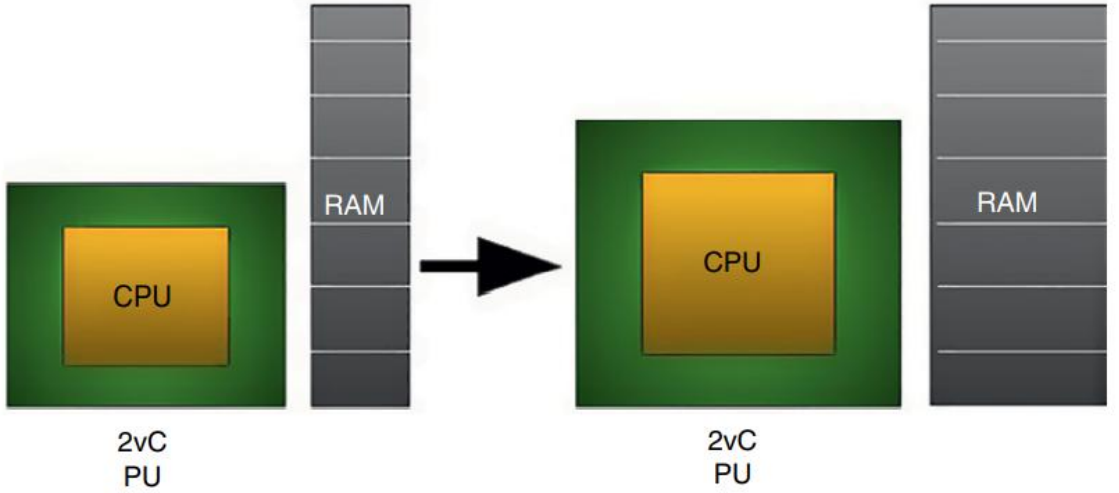
Hình 11: Biểu tượng biểu diễn hệ thống tập tin phân tán

5. Cách thức mở rộng hệ thống

- Khả năng mở rộng là khả năng của hệ thống đáp ứng nhu cầu ngày càng tăng về dung lượng lưu trữ.
- Một hệ thống có khả năng mở rộng quy mô mang lại hiệu suất và hiệu quả cao hơn.
- Với sự ra đời của kỷ nguyên dữ liệu lớn, nhu cầu cấp thiết phải mở rộng các nền tảng lưu trữ dữ liệu để có thể lưu trữ hàng petabyte dữ liệu.
- Các nền tảng lưu trữ có thể được mở rộng theo hai cách
  - Khả năng mở rộng theo chiều dọc (Scaling – up)
  - Khả năng mở rộng theo chiều ngang (Scaling – out)

Mở rộng theo chiều dọc (Scaling – up)

- Khả năng mở rộng theo chiều dọc bổ sung thêm tài nguyên cho máy chủ hiện có để tăng khả năng chứa và xử lý nhiều dữ liệu hơn.
  - Các tài nguyên có thể là khả năng tính toán, ổ cứng, RAM… Loại mở rộng này bị giới hạn bởi khả năng mở rộng tối đa của máy chủ.
- Hình 12 cho thấy kiến trúc mở rộng theo chiều dọc trong đó dung lượng RAM của một máy được nâng cấp từ 32GB lên 128GB để đáp ứng nhu cầu ngày càng cao.

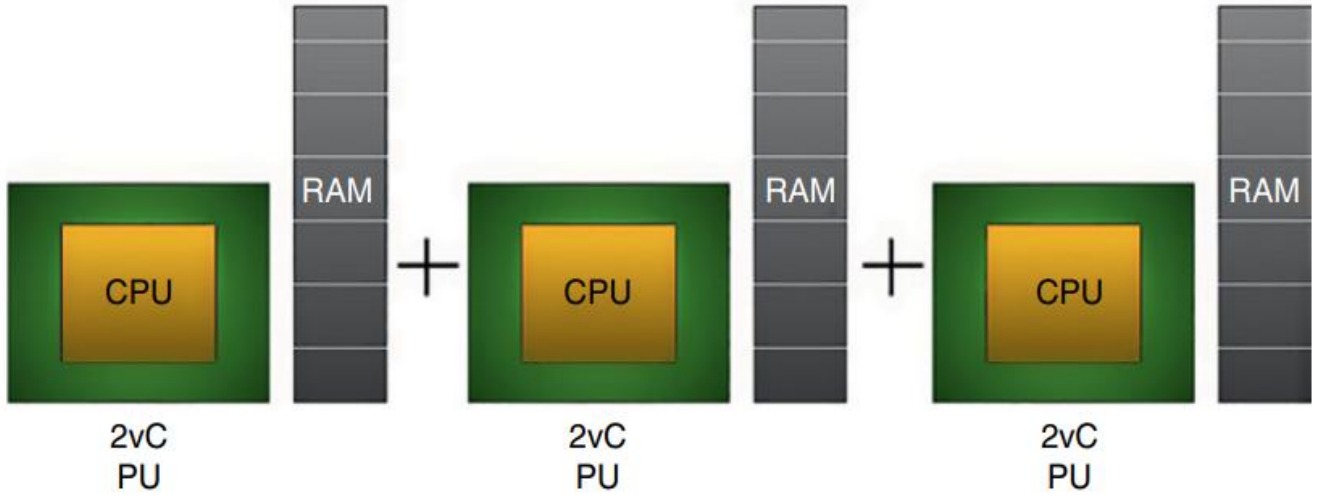


Hình 12: Kiến trúc Scaling - up

Mở rộng theo chiều ngang (Scaling – out)

- Khả năng mở rộng theo chiều ngang thêm nhiều server hoặc các thành phần mới để đáp ứng nhu cầu ngày càng cao.
- Thành phần bổ sung được thêm vào được gọi là các node.
- Công nghệ dữ liệu lớn hoạt động trên cơ sở mở rộng dung lượng lưu trữ.
- Việc mở rộng dung lượng lưu trữ sử dụng các thành phần lưu trữ và phần cứng thương mại chi phí thấp.
- Các thành phần có thể được thêm vào theo yêu cầu mà không quá phức tạp.
- Nhiều thành phần kết nối với nhau để hoạt động như một thực thể duy nhất.

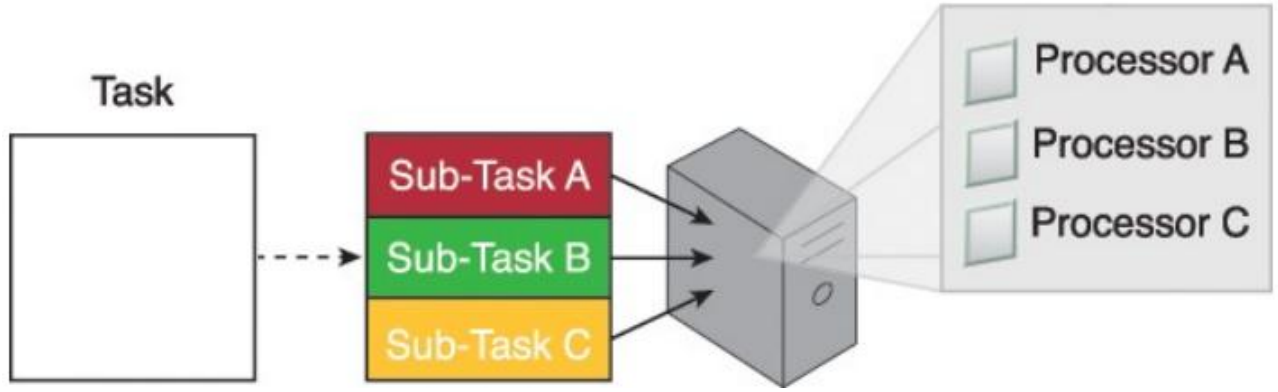
- Hình 13 cho thấy kiến trúc mở rộng theo chiều ngang trong đó công suất được tăng lên bằng cách thêm các phần cứng thương mại bổ sung vào cụm để đáp ứng nhu cầu ngày càng tăng.



Hình 13: Kiến trúc Scaling - out

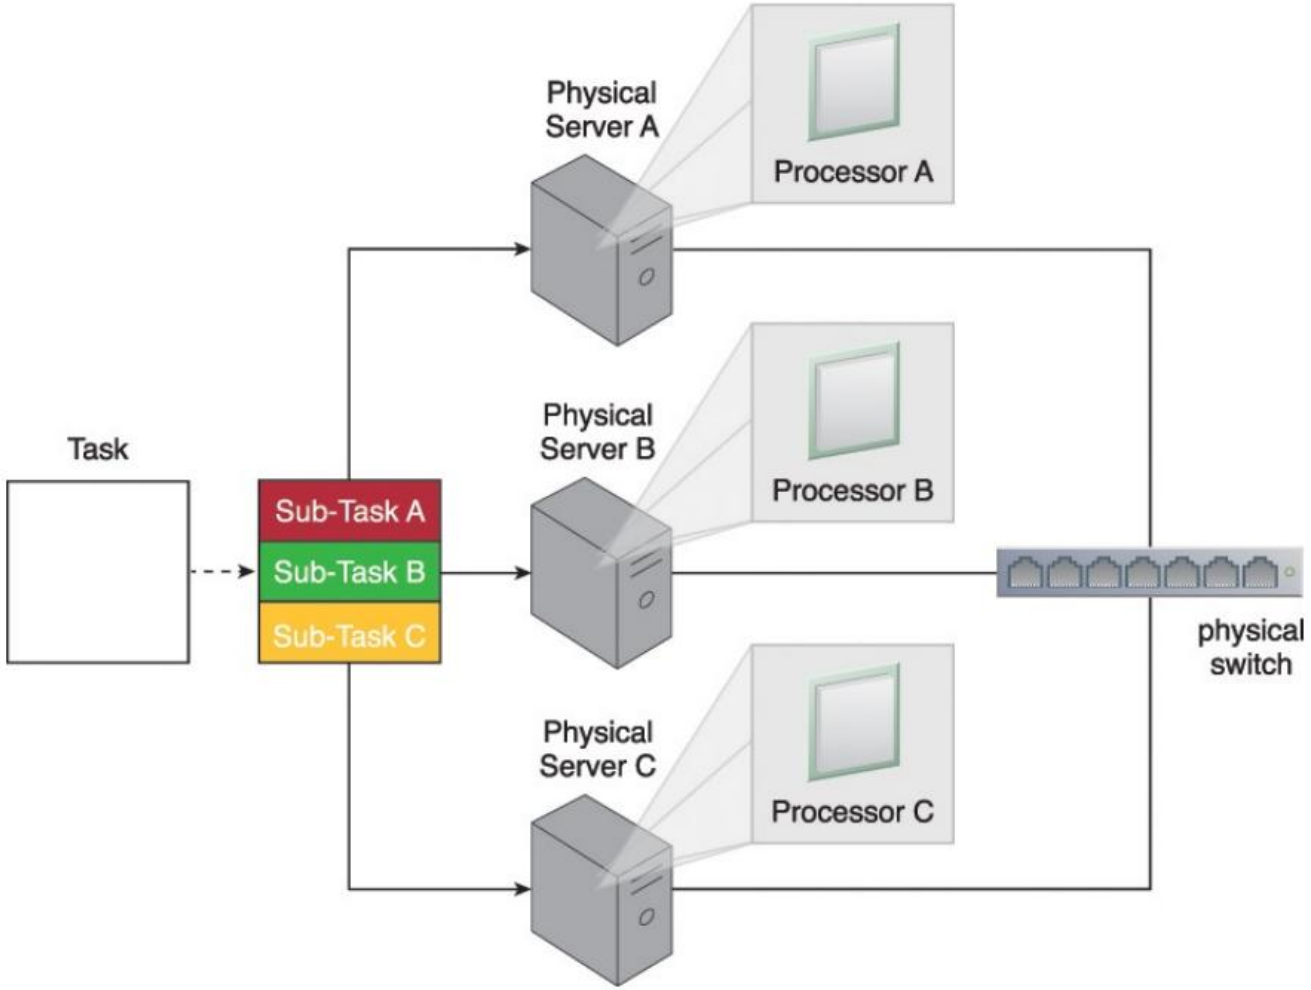
- Khi dữ liệu được thu thập, quá trình xử lý dữ liệu bắt đầu. Về cơ bản có 02 loại: xử lý dữ liệu tập trung và xử lý dữ liệu phân tán
- **Xử lý dữ liệu tập trung** là kỹ thuật xử lý yêu cầu tài nguyên tối thiểu và phù hợp với các tổ chức có một điểm dịch vụ tập trung.
- **Xử lý dữ liệu phân tán** là một kỹ thuật xử lý trong đó việc thu thập và xử lý dữ liệu được phân tán trên các vị trí thực tế khác nhau. Kiểu xử lý này khắc phục những thiếu sót của xử lý dữ liệu tập trung mà bắt buộc việc thu thập dữ liệu tại một địa điểm trung tâm. Xử lý dữ liệu phân tán được thực hiện bởi một số kiến trúc, cụ thể là kiến trúc khách – chủ (client – server), kiến trúc ba tầng (three – tier), kiến trúc n tầng (n – tier), kiến trúc cụm (cluster) và kiến trúc ngang hàng (peer – to – peer).

- **Xử lý dữ liệu song song**
- Tính toán song song là quá trình chia một tác vụ (task) lớn hơn thành nhiều tác vụ con và thực hiện chúng đồng thời để giảm thời gian thực hiện tổng thể. Việc thực thi các tác vụ con được thực hiện bởi nhiều bộ xử lý bên trong một máy đơn.
- Hình 14 hiển thị xử lý dữ liệu song song trong đó một tác vụ được chia thành các tác vụ con A, B, C và được thực thi bởi các bộ xử lý A, B, C cùng chạy trên một máy.



Hình 14: Xử lý dữ liệu song song

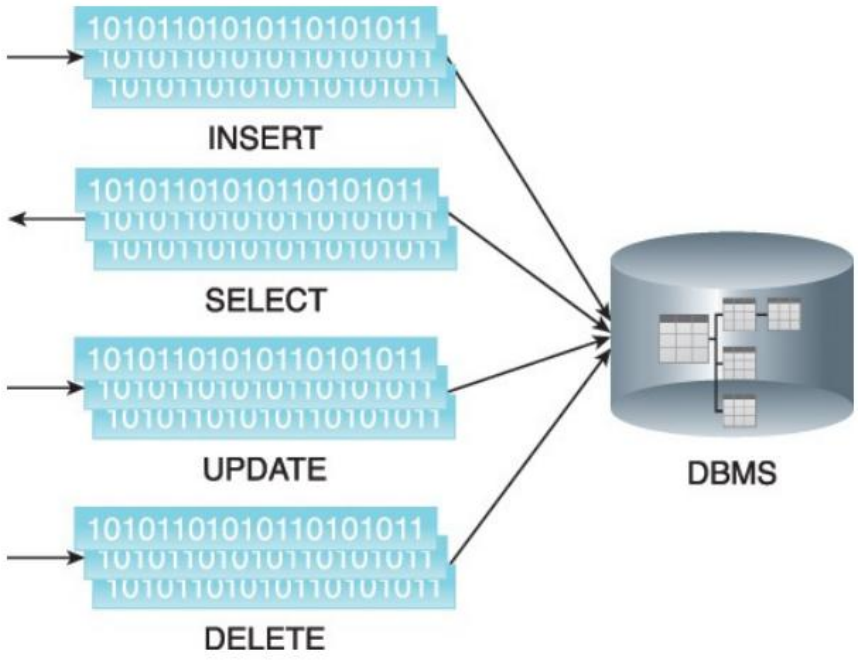
- **Xử lý dữ liệu phân tán**
- Xử lý dữ liệu phân tán tương tự như xử lý dữ liệu song song, chia các tác vụ lớn hơn thành các tác vụ con, nhưng quá trình thực thi các tác vụ con diễn ra trong các máy riêng biệt được kết nối thông qua mạng để tạo thành một cụm đồng nhất.
- Hình 15 hiển thị xử lý dữ liệu phân tán trong đó một tác vụ được chia thành các tác vụ con A, B, C và được thực thi bởi các bộ xử lý A, B, C chạy trên các máy khác nhau được kết nối với nhau.



Hình 15: Xử lý dữ liệu phân tán

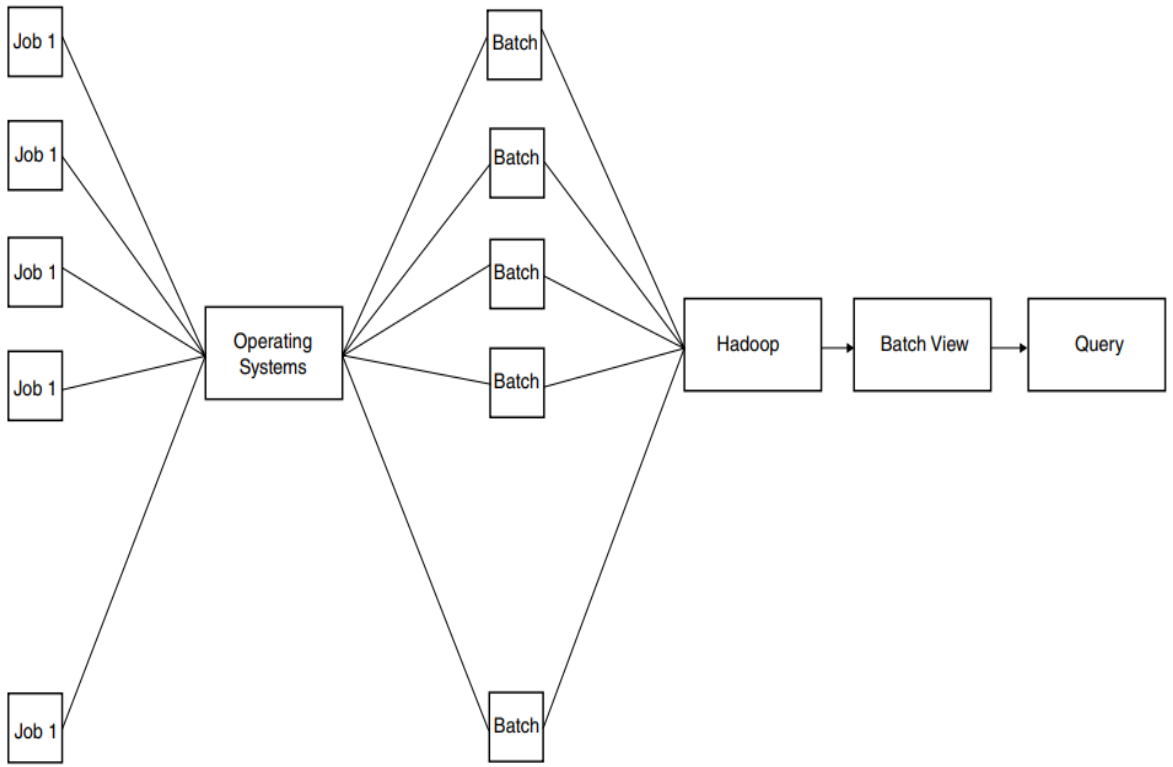
- **Xử lý dữ liệu hàng loạt**
- **Khối lượng công việc xử lý (workload) trong dữ liệu lớn được định nghĩa là số lượng và tính chất của dữ liệu được xử lý trong một khoảng thời gian nhất định.**
- **Khối lượng công việc được chia thành hai loại**
  - **Theo lô (batch)**
  - **Theo giao dịch (transaction)**

- Xử lý hàng loạt (batch processing) hay còn gọi là xử lý ngoại tuyến thường gây ra độ trễ. Thời gian phản hồi có thể thay đổi từ vài phút đến vài giờ.
- Khối lượng công việc thường liên quan đến số lượng lớn dữ liệu với khả năng đọc/ghi tuần tự và bao gồm các nhóm truy vấn đọc và ghi dữ liệu.
- Các câu truy vấn có thể phức tạp và liên quan đến nhiều phép kết.
- Các hệ thống OLAP thường xử lý khối lượng công việc theo lô. Việc phân tích và trí tuệ kinh doanh (Business Intelligence - BI) có chiến lược thường được định hướng hàng loạt vì đây là những tác vụ cần đọc nhiều liên quan đến khối lượng dữ liệu lớn.



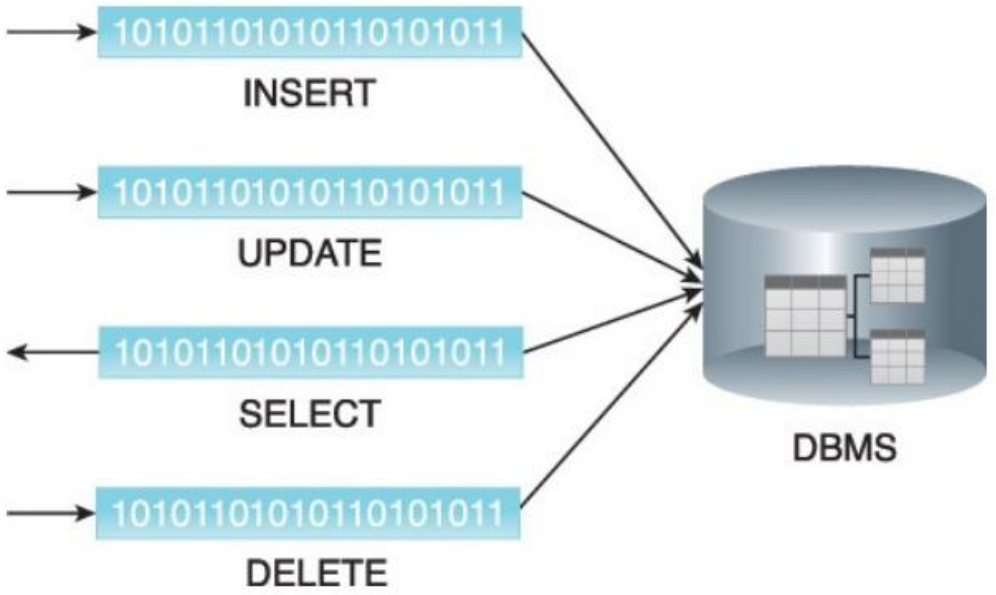
Hình 16: Khối lượng công việc xử lý hàng loạt gồm các nhóm lệnh đọc/ghi

- Trong dữ liệu lớn, xử lý hàng loạt trong đó chuỗi công việc có kết nối luận lý được thực hiện tuần tự hoặc song song, sau đó kết quả của tất cả các công việc riêng lẻ được tập hợp lại để tạo ra kết quả cuối cùng.
- Xử lý hàng loạt được thực hiện bằng cách thu thập dữ liệu theo lô và xử lý chúng để tạo kết quả và kết quả này có thể là đầu vào của một quy trình xử lý khác.
- Loại xử lý này phù hợp với các ứng dụng với hàng terabyte hoặc petabyte dữ liệu mà thời gian đáp ứng không quan trọng vì thường có độ trễ cao.



Hình 17: Xử lý dữ liệu theo lô được triển khai bằng kiến trúc MapReduce của Hadoop

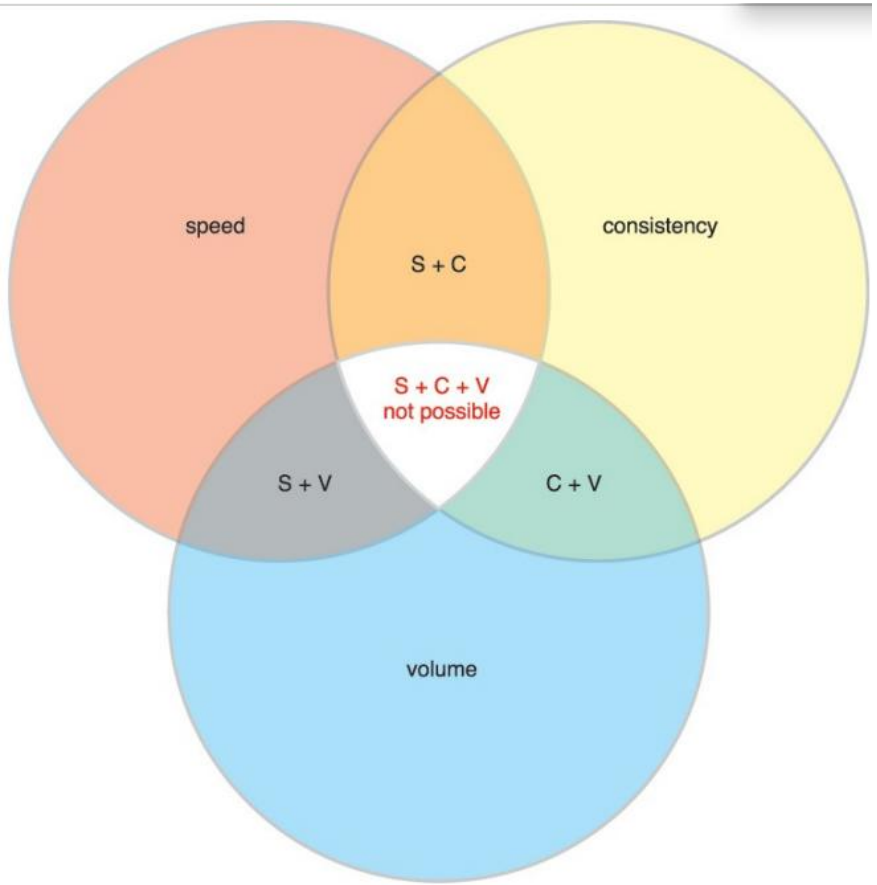
- **Xử lý giao dịch** hay còn gọi là **xử lý trực tuyến**.
- Dữ liệu được xử lý một cách tương tác mà không bị chậm trễ, dẫn đến các phản hồi có độ trễ thấp.
- Khối lượng công việc giao dịch bao gồm một lượng nhỏ dữ liệu với các lần đọc và ghi ngẫu nhiên.
- Các hệ thống OLTP và hệ điều hành có nhiều thao tác ghi, thuộc loại xử lý giao dịch. Mặc dù các khối lượng công việc này chứa hỗn hợp các câu truy vấn đọc/ghi nhưng thường các thao tác ghi nhiều hơn đọc và có chứa ít phép kết hơn so với BI và khối lượng công việc báo cáo, thống kê.



Hình 18: Xử lý dữ liệu giao dịch

- **Xử lý dữ liệu theo thời gian thực**
- **Xử lý dữ liệu theo thời gian thực (Realtime) còn được gọi là xử lý sự kiện hoặc luồng vì dữ liệu đến liên tục (stream) hoặc theo khoảng thời gian (sự kiện).**
- **Dữ liệu được xử lý trên bộ nhớ do yêu cầu phân tích dữ liệu trong khi truyền phát (streaming). Thời gian phản hồi thường dao động từ dưới một giây đến dưới một phút. Sau đó dữ liệu được lưu trữ trên đĩa sau khi được xử lý.**
- **Dữ liệu luồng/sự kiện thường có kích thước nhỏ nhưng bản chất liên tục của nó tạo ra các bộ dữ liệu rất lớn.**

- **Định lý SCV (Speed Consistency Volume)**
- Trong khi định lý **CAP** chủ yếu liên quan đến việc lưu trữ dữ liệu phân tán thì định lý **SCV** liên quan đến việc xử lý dữ liệu phân tán, chủ yếu ảnh hưởng đến chế độ xử lý thời gian thực.
- Định lý SCV quy định một hệ thống xử lý dữ liệu phân tán chỉ có thể được thiết kế để hỗ trợ hai trong số ba tính chất sau
  - Tốc độ (Speed)
  - Nhất quán (Consistency)
  - Dung lượng (Volume)



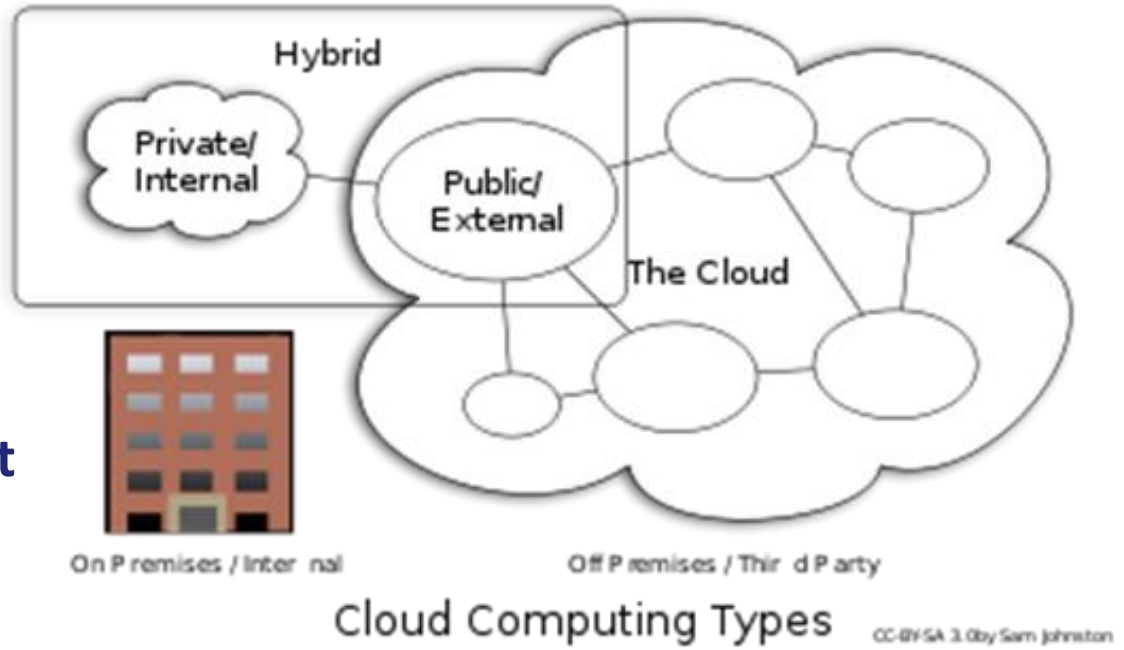
Hình 19: Biểu đồ Venn tóm tắt định lý SCV

7. Dữ liệu lớn và điện toán đám mây

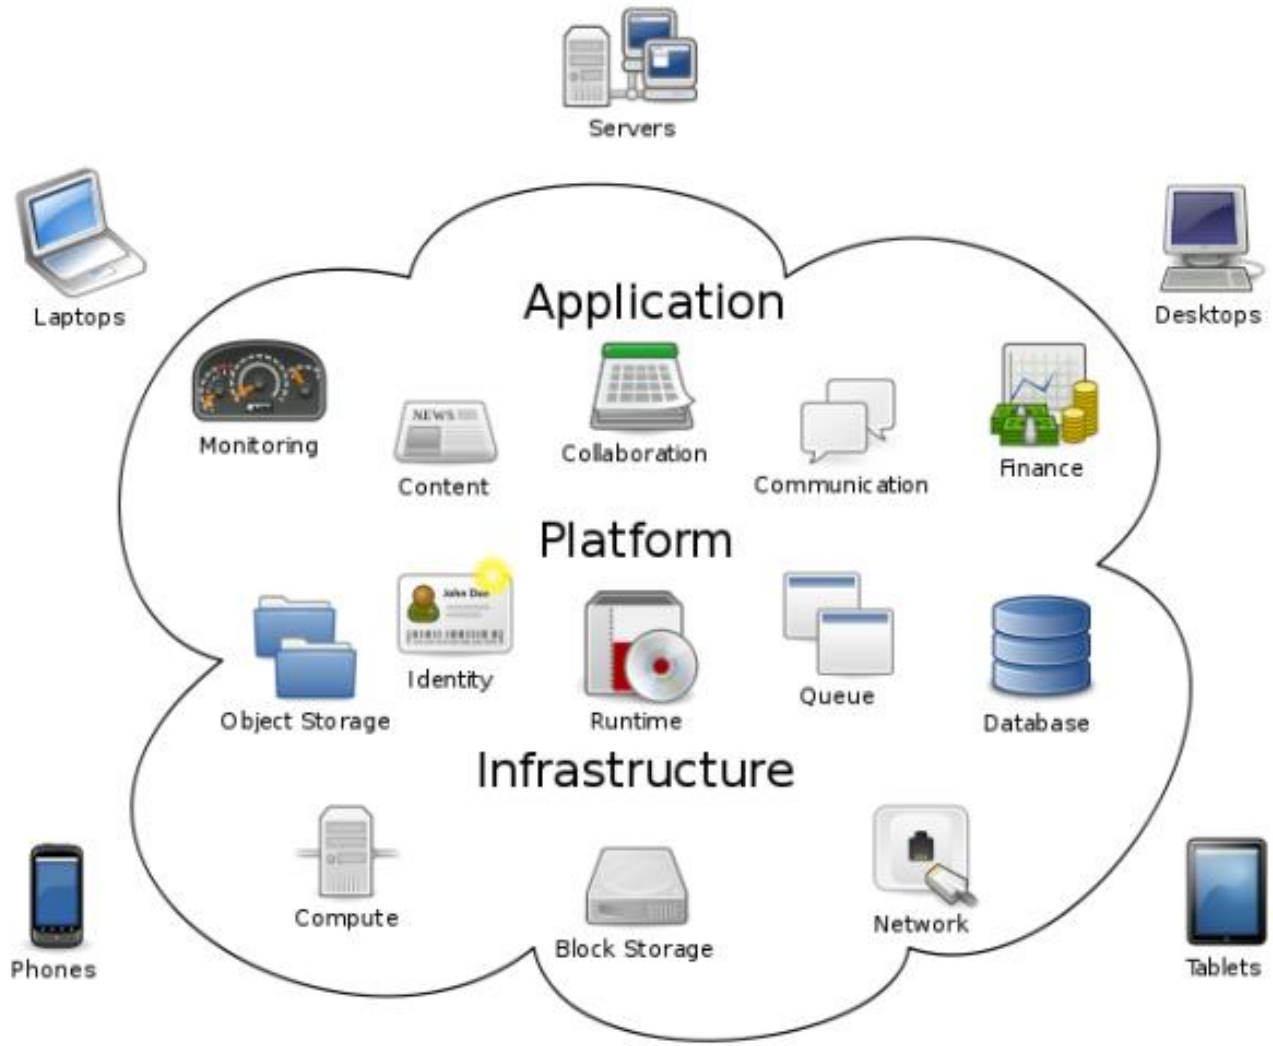
- Dữ liệu lớn thúc đẩy sự phát triển của tài chính điện tử, thương mại điện tử, giao thông thông minh, viễn thông và thành phố thông minh… Nhưng việc áp dụng chúng vào thực tế rất phức tạp và tốn thời gian.
- Điện toán đám mây đã sửa đổi cách thức truyền thống lưu trữ, truy cập và thao tác dữ liệu bằng cách áp dụng các khái niệm mới về lưu trữ và đem điện toán với dữ liệu gần hơn.
- Điện toán đám mây, gọi đơn giản là đám mây, là việc cung cấp các tài nguyên máy tính được chia sẻ và dữ liệu được lưu trữ theo yêu cầu.
- Để giảm đáng kể chi phí, các tổ chức đang sử dụng điện toán đám mây để cung cấp các tài nguyên cần thiết.
- Các trung tâm dữ liệu đám mây cung cấp tài nguyên vật lý quy mô lớn trong khi các nền tảng điện toán đám mây cung cấp khả năng lập kế hoạch và quản lý hiệu quả cho các giải pháp dữ liệu lớn. Do đó, điện toán đám mây về cơ bản cung cấp cơ sở hạ tầng hỗ trợ cho dữ liệu lớn. Nó giải quyết các vấn đề về tính toán và lưu trữ ngày càng tăng của dữ liệu lớn.

- Tài nguyên CNTT được cung cấp dưới dạng dịch vụ
  - Tài nguyên tính toán, lưu trữ, cơ sở dữ liệu, hàng đợi
- Điện toán đám mây tận dụng lợi thế quy mô của phần cứng thương mại
  - Lưu trữ giá rẻ, mạng băng thông cao và bộ xử lý đa lõi
  - Trung tâm dữ liệu phân tán theo địa lý
- Các dịch vụ từ Microsoft, Amazon, Google, …

- **Đám mây công cộng (Public Cloud)**: Cơ sở hạ tầng điện toán được đặt tại cơ sở của nhà cung cấp.
- **Đám mây riêng tư (Private Cloud)**: Kiến trúc điện toán dành riêng cho khách hàng và không được chia sẻ với các tổ chức khác.
- **Đám mây lai (Hybrid Cloud)**: Các tổ chức lưu trữ một số ứng dụng quan trọng, bảo mật trong đám mây riêng. Các ứng dụng không quan trọng được lưu trữ trong đám mây công cộng.
- **Đám mây cộng đồng (Community Cloud)**



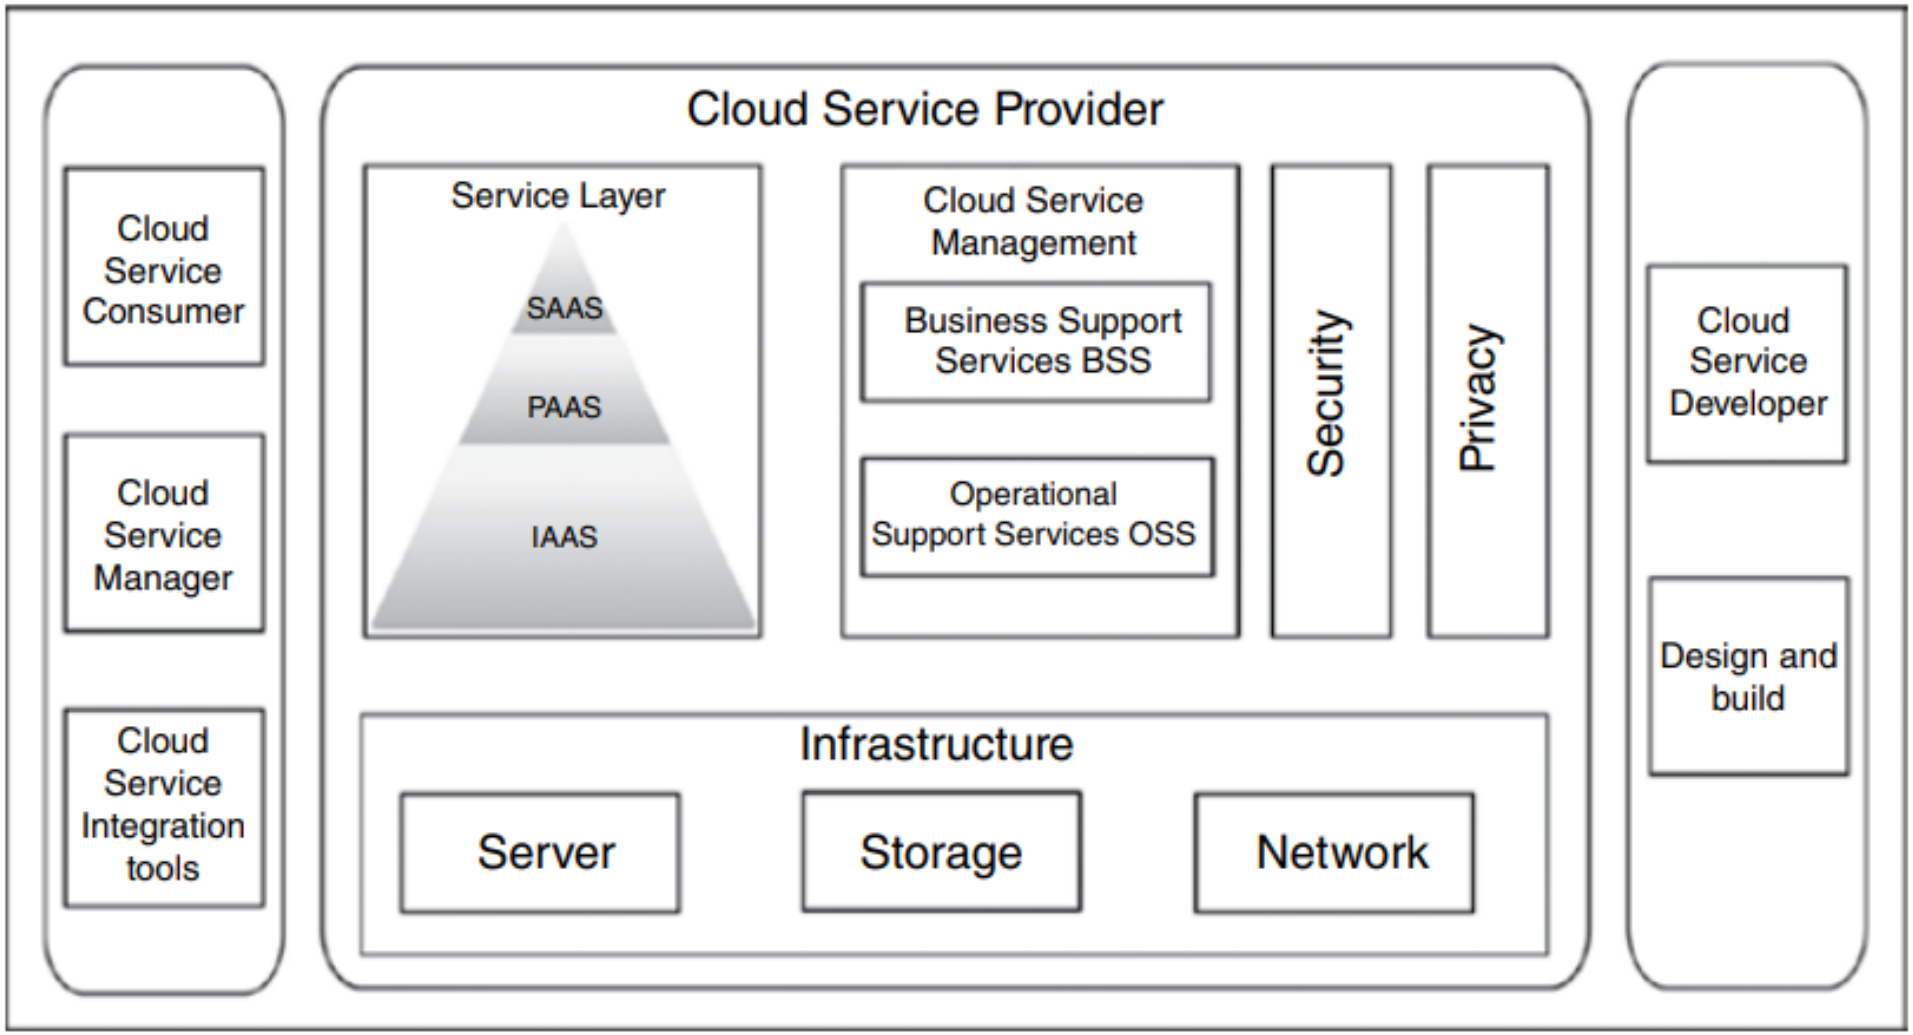
Hình 20: Các loại đám mây



Hình 21: Các dịch vụ điện toán đám mây

Các dịch vụ điện toán đám mây

- Cơ sở hạ tầng như một dịch vụ (IaaS)
  - Cung cấp các dịch vụ liên quan đến phần cứng sử dụng các nguyên tắc của điện toán đám mây. Chúng có thể bao gồm các dịch vụ lưu trữ (cơ sở dữ liệu hoặc lưu trữ đĩa) hoặc máy chủ ảo.
  - Amazon EC2, Amazon S3, Rackspace Cloud Servers và Flexiscale.
- Nền tảng như một dịch vụ (PaaS)
  - Cung cấp nền tảng phát triển trên đám mây.
  - Google Application Engine, Microsoft Azure, Salesforce.com.
- Phần mềm như một dịch vụ (SaaS)
  - Bao gồm một gói phần mềm hoàn chỉnh trên đám mây. Người dùng có thể truy cập ứng dụng phần mềm được lưu trữ bởi nhà cung cấp đám mây trên cơ sở trả phí theo mức sử dụng. Đây là một lĩnh vực đã được thiết lập vững chắc.
  - Các dịch vụ của Salesforce.com trong lĩnh vực Quản lý quan hệ khách hàng (CRM) trực tuyến, Google Gmail và Microsoft Hotmail, Google Docs.



Hình 22: Kiến trúc của điện toán đám mây

8. Tổng kết

1. Điện toán cụm
2. Các mô hình phân tán
3. Hệ thống tập tin phân tán
4. Cách thức mở rộng hệ thống
5. Các kỹ thuật xử lý dữ liệu lớn
6. Dữ liệu lớn và điện toán đám mây

Câu 1: Quá trình thu thập, xử lý, thao tác và quản lý dữ liệu để tạo ra thông tin có ý nghĩa cho người dùng cuối được gọi là _____

a. Thu thập dữ liệu (Data Acquisiton)

b. Xử lý dữ liệu (Data Processing)

c. Tích hợp dữ liệu (Data Integration)

d. Chuyển đổi dữ liệu (Data Transformation)

Câu 2: Kiến trúc điện toán cụm ra đời là kết quả của

a. ISA

b. Worstation

c. Supercomputers

d. Distributed System

Câu 3: Các cụm tuân thủ cơ chế _____ để loại bỏ gián đoạn dịch vụ

a. Sharding (Phân mảnh)

b. Replication (Nhân bản)

c. Failover (Chuyển đổi dự phòng)

d. Partition (Phân vùng)

Câu 4: _____ là quá trình chuyển sang một node dự phòng khi có sự kết thúc bất thường hoặc lỗi xảy ra trên một node đang hoạt động trước đó

a. Sharding (Phân mảnh)

b. Replication (Nhân bản)

c. Failover (Chuyển đổi dự phòng)

d. Partition (Phân vùng)

Câu 5: ____ thêm nhiều tài nguyên lưu trữ và CPU để tăng dung lượng

Mở rộng theo chiều ngang

Mở rộng theo chiều dọc

Phân vùng

Tất cả đều đúng

Câu 6: ____ là quá trình sao chép các khối dữ liệu giống nhau qua nhiều node

a. Nhân bản

b. Phân vùng

c. Phân mảnh

d. Tất cả đều sai

Câu 7: ____ là quá trình phân chia tập dữ liệu và phân phối dữ liệu trên nhiều máy chủ

a. Mở rộng theo chiều dọc

b. Phân mảnh

c. Phân vùng

d. Tất cả đều đúng

Câu 8: Quá trình chia một tác vụ lớn hơn thành nhiều tác vụ con và thực hiện chúng đồng thời để giảm thời gian thực hiện tổng thể được gọi là _____

a. Tính toán song song

b. Tính toán phân toán

c. Câu a, b đều đúng

d. Câu a, b đều sai

Câu 9: _____ được sử dụng trong phân tích nhật ký (log) trong đó dữ liệu được thu thập theo thời gian và việc phân tích được thực hiện.

a. Xử lý theo lô

b. Xử lý theo thời gian thực

c. Xử lý song song

d. Tất cả đều sai

Câu 10: Kiến trúc đám mây trong trung tâm dữ liệu doanh nghiệp được gọi là?

a. Đám mây công cộng

b. Đám mây riêng tư

c. Đám mây lai

d. Tất cả đều sai

Câu 11: Sự khác biệt giữa chuyển đổi dự phòng và chuyển đổi qua lại là gì?

Câu 12: Phân biệt Cụm có tính sẵn sàng cao và Cụm cân bằng tải

Câu 13: Phân biệt Cụm đối xứng và Cụm bất đối xứng

Câu 14: Phân biệt giữa nhân bản và phân mảnh dữ liệu

Câu 15: Xử lý dữ liệu theo lô là gì?

Câu 16: Xử lý dữ liệu theo thời gian thực là gì?

Câu 17: Định lý SCV là gì?

Câu 18: Xử lý dữ liệu song song là gì?

Câu 19: Xử lý dữ liệu phân tán là gì?

Câu 20: Đăng ký sử dụng và so sánh các dịch vụ cloud của Microsoft, Amazon, Google



Trung tâm Học liệu và Dạy học số

Đại học Công nghệ Kỹ thuật Tp. Hồ Chí Minh

01 Võ Văn Ngân, P. Thủ Đức, Tp.Hồ Chí Minh

daotaotuxa@hcmute.edu.vn