TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
HCM·UTE
HCMC University of Technology and Engineering

[BDES333877] Nhập Môn Dữ Liệu Lớn

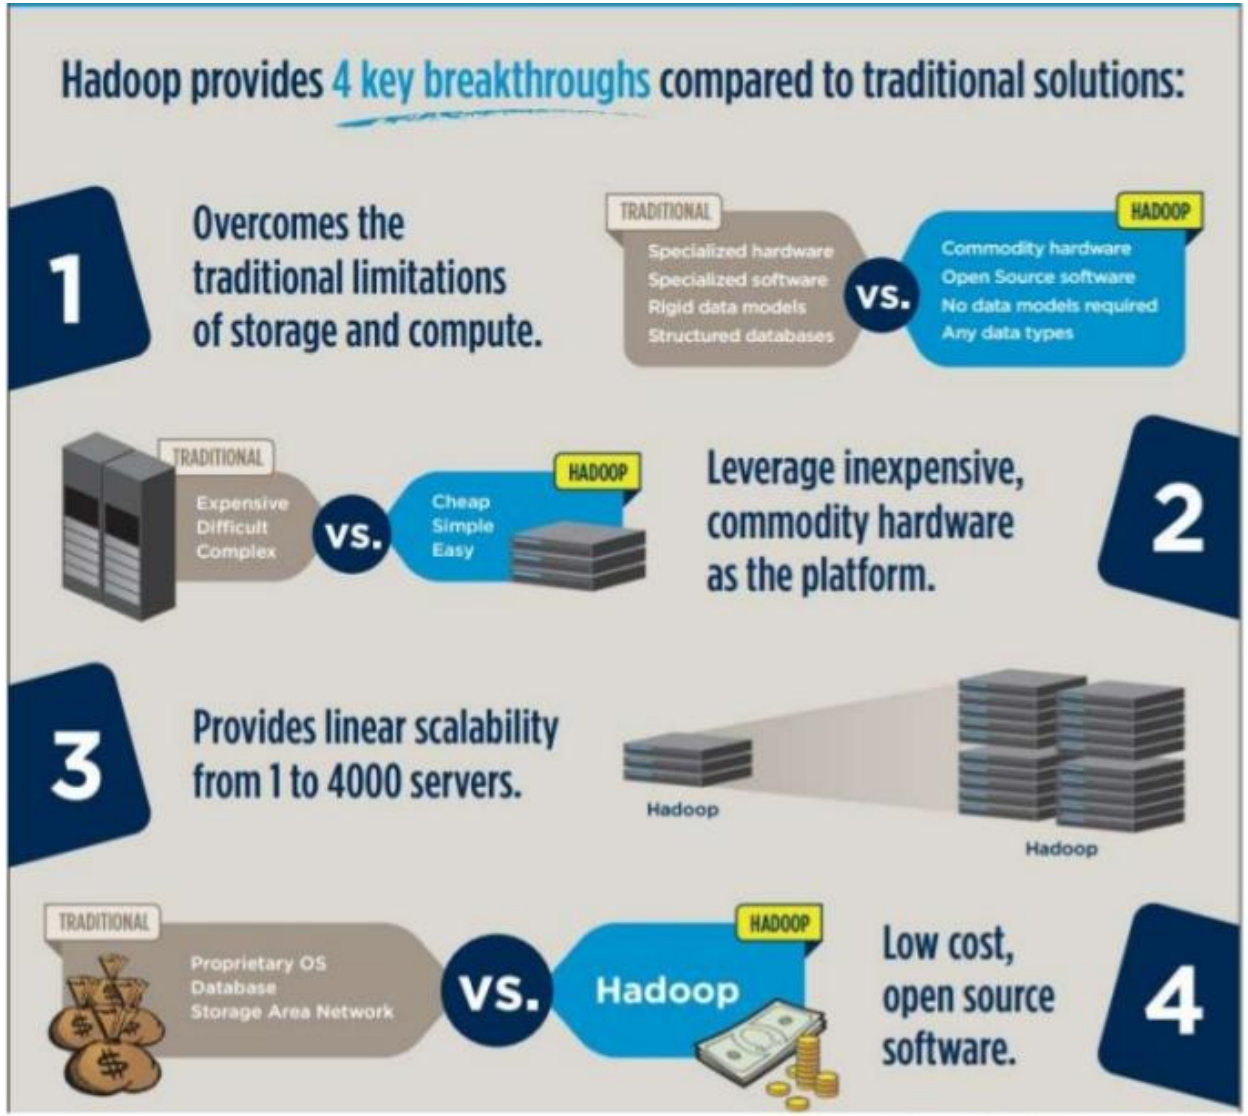
CHƯƠNG 03: CÁC CÔNG CỤ LƯU TRỮ VÀ XỬ LÝ DỮ LIỆU LỚN

ThS. Lê Thị Minh Châu

Nội dung của bài học

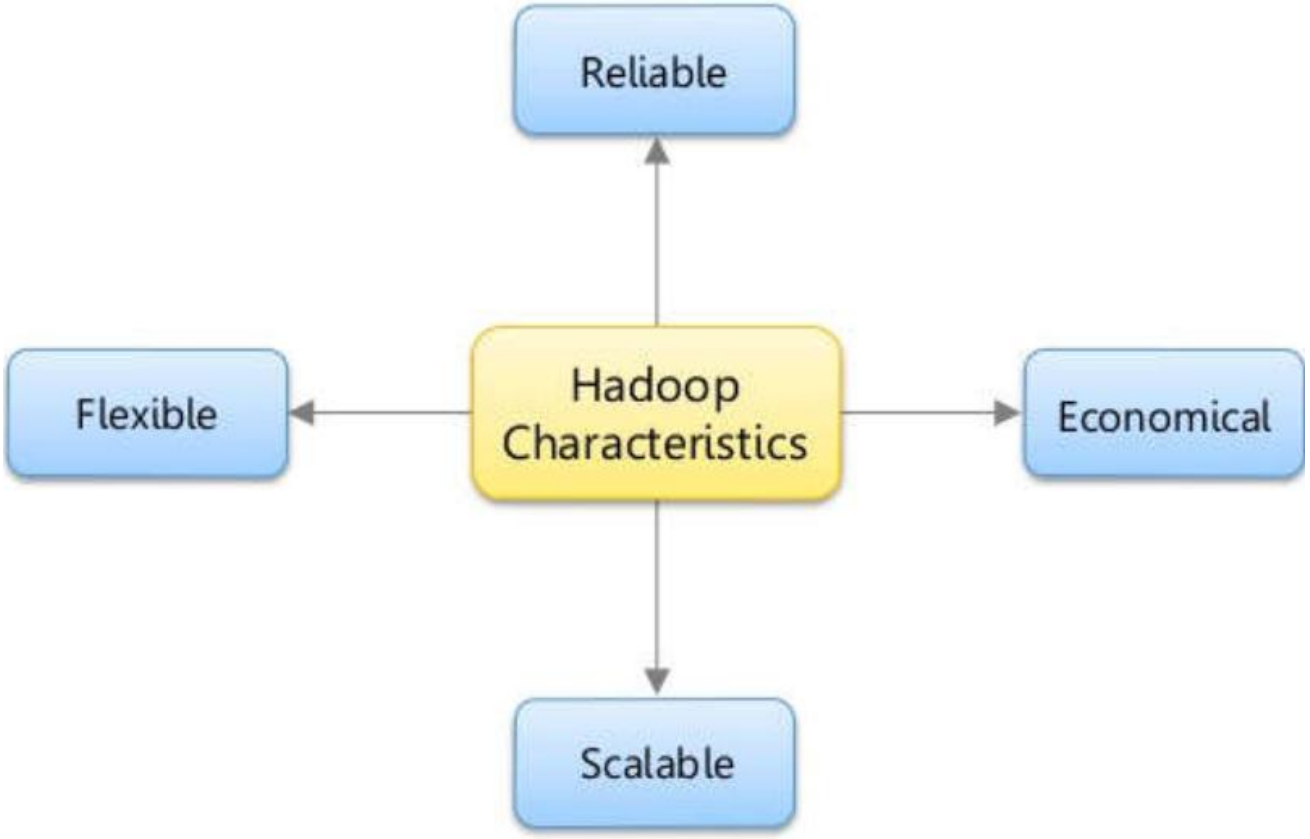
1. Đặt vấn đề
2. Giới thiệu Apache Hadoop
3. Các thành phần chính của Apache Hadoop
4. Hệ sinh thái Hadoop
5. Tổng kết
6. Bài tập

- Kiến trúc / framework nào hỗ trợ triển khai hệ thống Dữ Liệu Lớn?
- Các công cụ hỗ trợ?
- Làm sao cài đặt / mô phỏng một hệ thống Dữ Liệu Lớn?



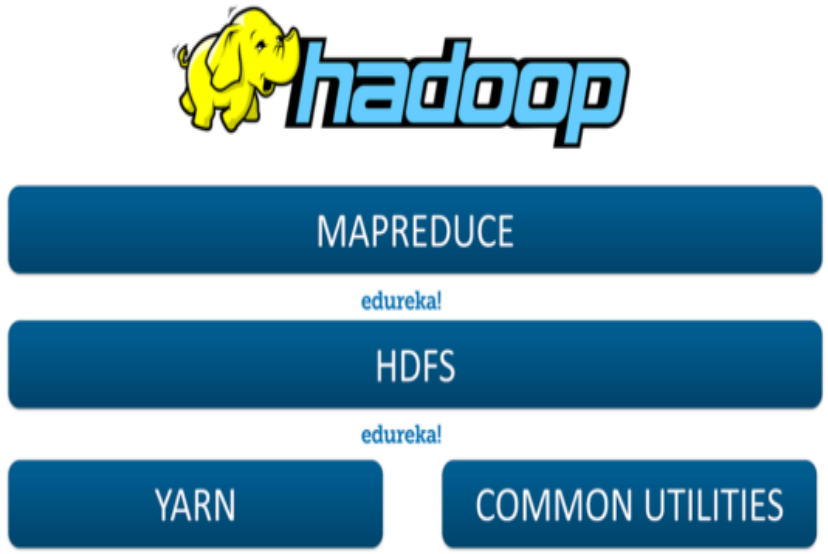
Hình 1: Các đột phá của Apache Hadoop so với các giải pháp truyền thống

- **Apache Hadoop** là một khung phần mềm (**framework**) cho phép xử lý phân tán các tập dữ liệu lớn trên các cụm máy tính thương mại (**commodity computers**) bằng mô hình lập trình đơn giản.
- Đây là công nghệ quản lý dữ liệu mã nguồn mở với khả năng lưu trữ mở rộng và xử lý phân tán.

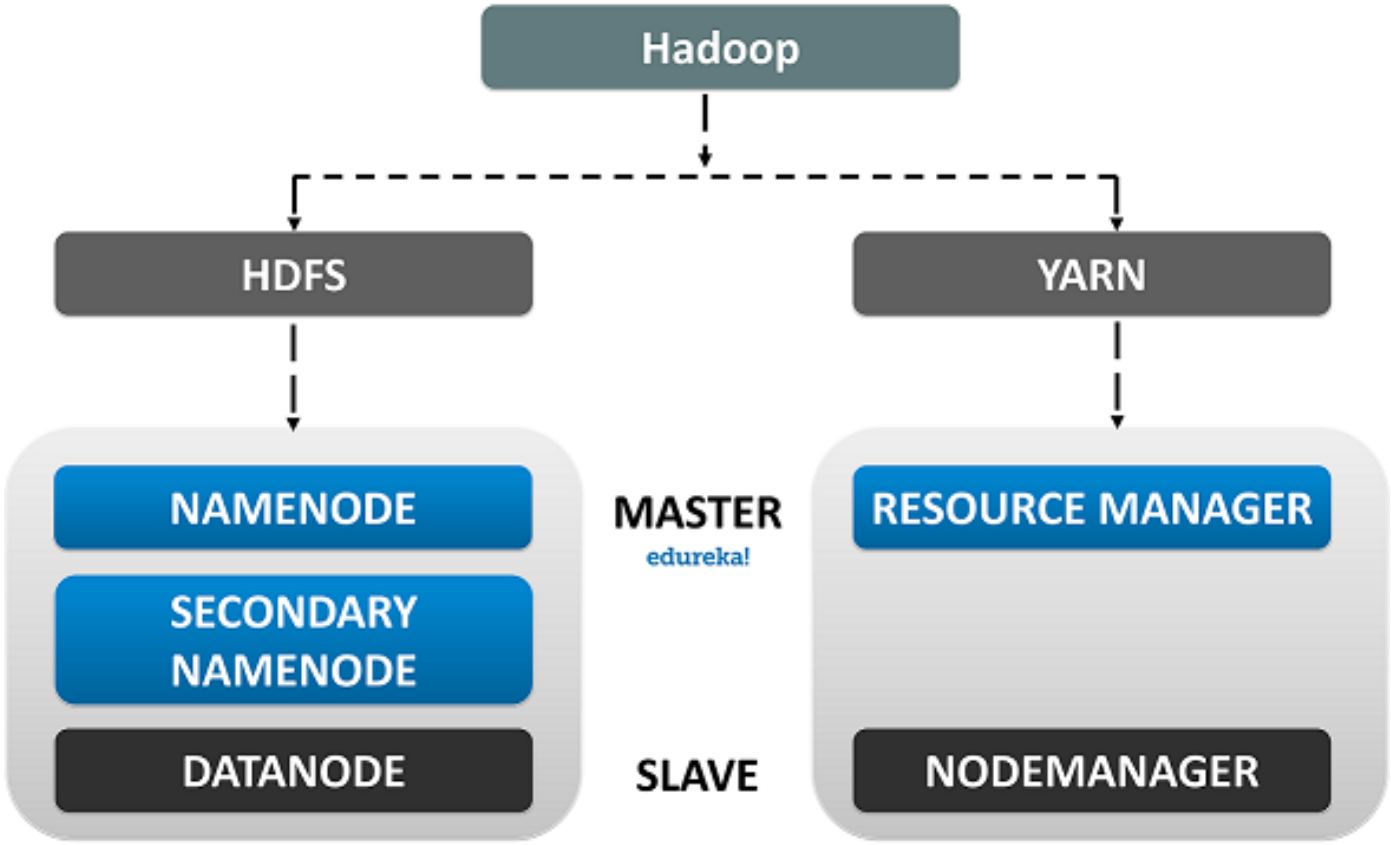


Hình 2: Các đặc điểm của Apache Hadoop

- MapReduce
- HDFS
- YARN



Hình 3: Các thành phần chính của Apache Hadoop

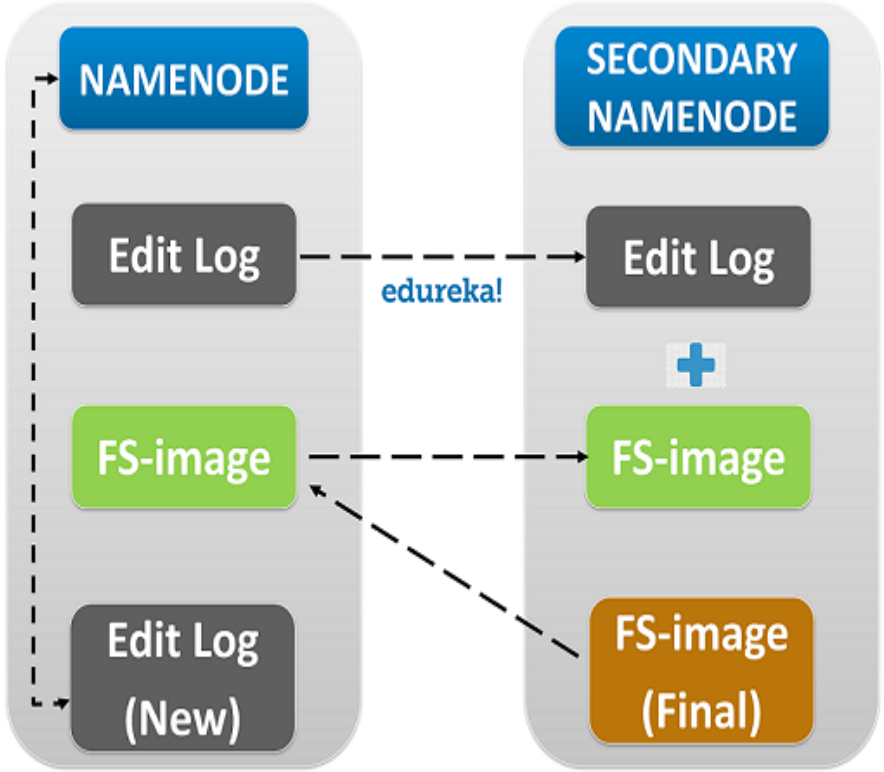


Hình 4: Kiến trúc của Apache Hadoop

- **Mô hình MapReduce**
- **Mô hình MapReduce (còn được gọi là MR) là mô hình xử lý dữ liệu phân tán và môi trường thực thi chạy trên các cụm máy tính thương mại quy mô lớn.**
- **Các chương trình viết theo mô hình MapReduce về cơ bản là hoạt động song song.**
- **Bao gồm 02 giai đoạn:**
  - **Map (ánh xạ): nhận dữ liệu và tập hợp dữ liệu, sau đó chia chúng thành các phần nhỏ để chuyển đổi thành định dạng mới dưới dạng cặp khóa-giá trị (key – value).**
  - **Reduce (thu giảm): các cặp khóa/giá trị được giảm xuống thành các bộ dữ liệu (tuple).**
- **MapReduce cho phép chúng ta thực hiện nhiều thao tác khác nhau trên Dữ Liệu Lớn như Lọc, Sắp xếp và nhiều bài toán tương tự khác.**

- **Apache Hadoop File System - HDFS**
- **Hệ thống tập tin phân tán Hadoop, có khả năng mở rộng và di động được viết bằng ngôn ngữ Java cho framework Hadoop.**
- **Cung cấp khả năng truy cập dữ liệu ứng dụng với thông lượng cao.**
- **Chạy trên các cụm lớn gồm các máy tính thương mại.**
- **Được sử dụng để lưu trữ các tập dữ liệu lớn.**

- NameNode
- DataNode
- Secondary NameNode

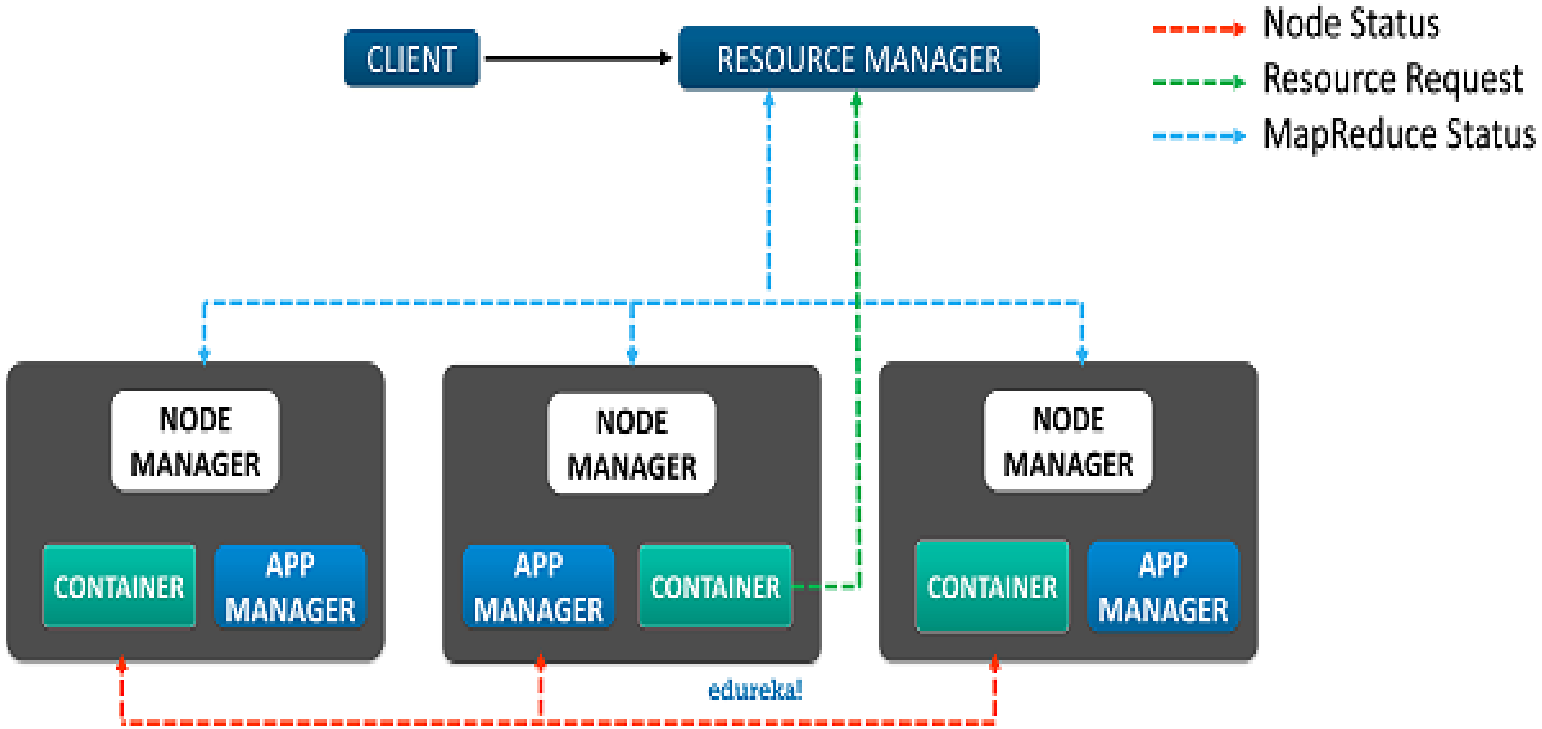


Hình 5: Các thành phần của HDFS

Các thành phần của HDFS

- **NameNode**
  - Thành phần trung tâm của HDFS (được gọi là **Master**)
  - Lưu trữ siêu dữ liệu của cụm
  - Chịu trách nhiệm giám sát tình trạng hoạt động của các nút SlaveNode và phân công nhiệm vụ cho các nút dữ liệu DataNode.
- **DataNode**
  - Đơn vị thực tế lưu trữ dữ liệu (được gọi là **Slave**)
  - Phản hồi cho NameNode về tình trạng hoạt động và trạng thái nhiệm vụ dưới dạng tín hiệu theo định kỳ (HeartBeat).
  - Nếu không phản hồi cho NameNode, thì NameNode coi SlaveNode này là đã chết (dead) và phân công lại nhiệm vụ cho DataNode khả dụng tiếp theo.
- **Secondary NameNode**
  - Không phải là bản sao lưu của NameNode, mà hoạt động như một bộ đệm cho NameNode.
  - Lưu trữ các bản cập nhật tức thời của FS-image của NameNode trong Edit-log và cập nhật thông tin vào FS-image cuối cùng khi NameNode không hoạt động.

- Yet Another Resource Negotiator - YARN
- Được cập nhật them vào Hadoop từ phiên bản thứ 2 trở đi.
- Chịu trách nhiệm quản lý tài nguyên và lập lịch công việc.

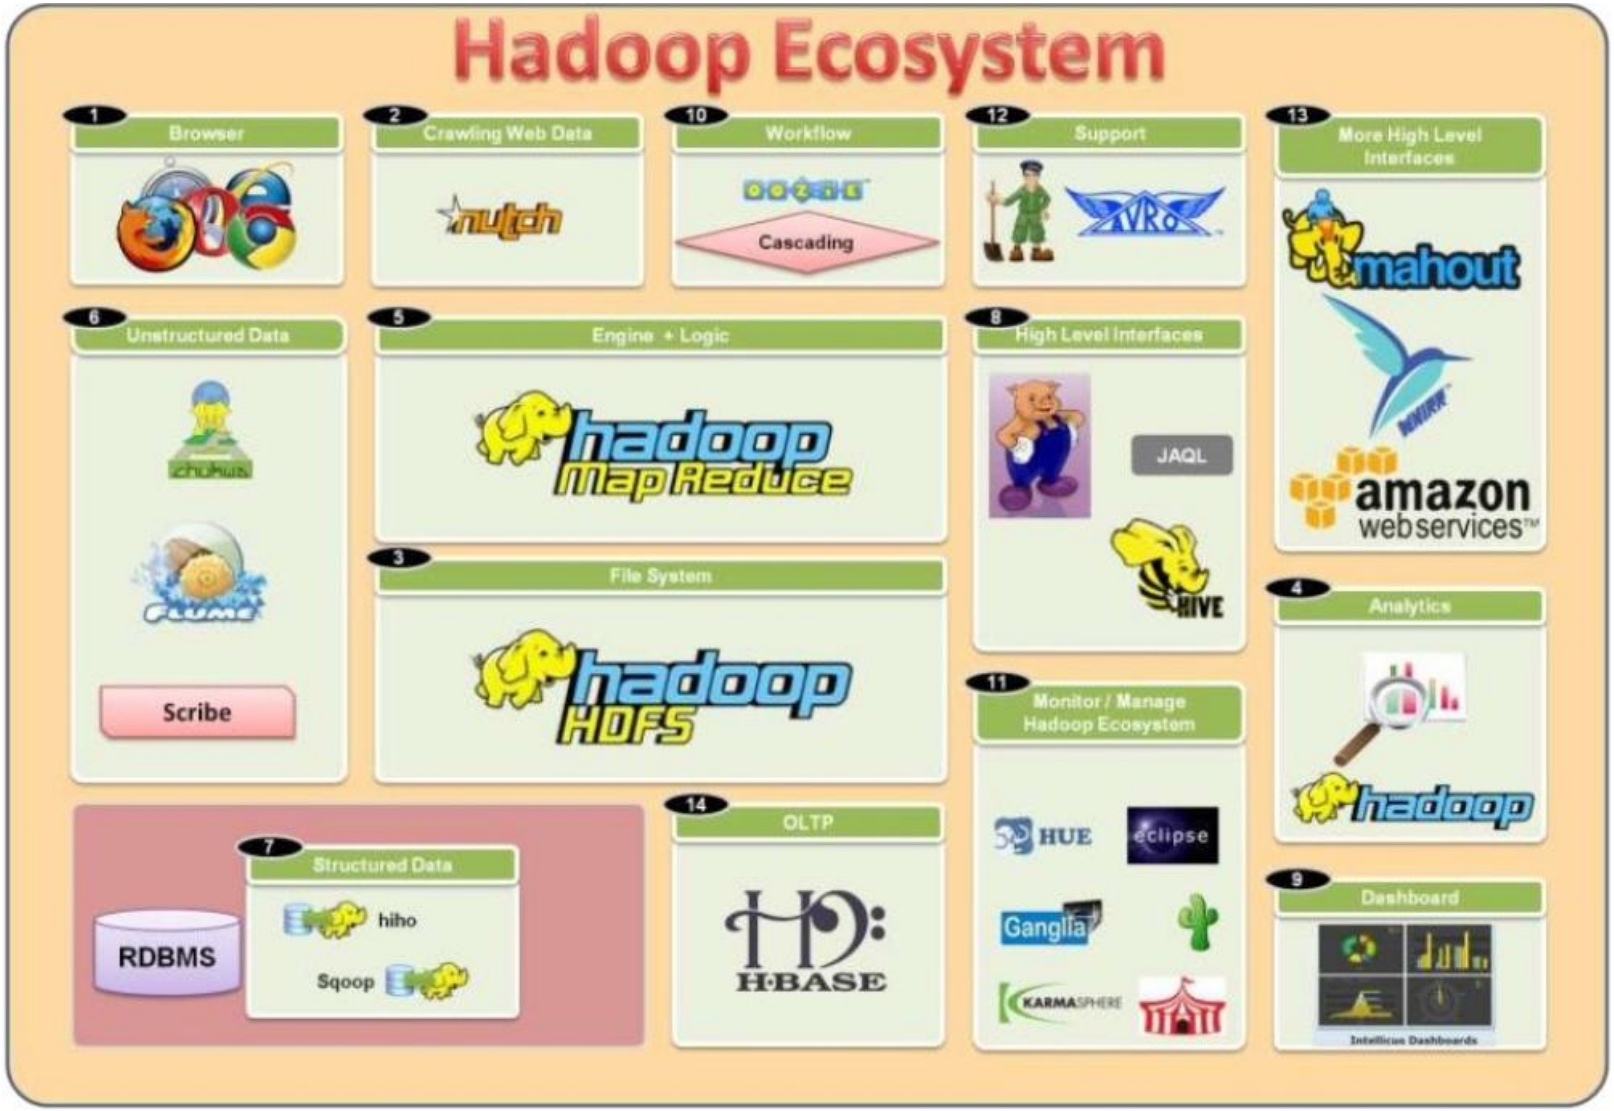


Hình 6: Các thành phần của YARN

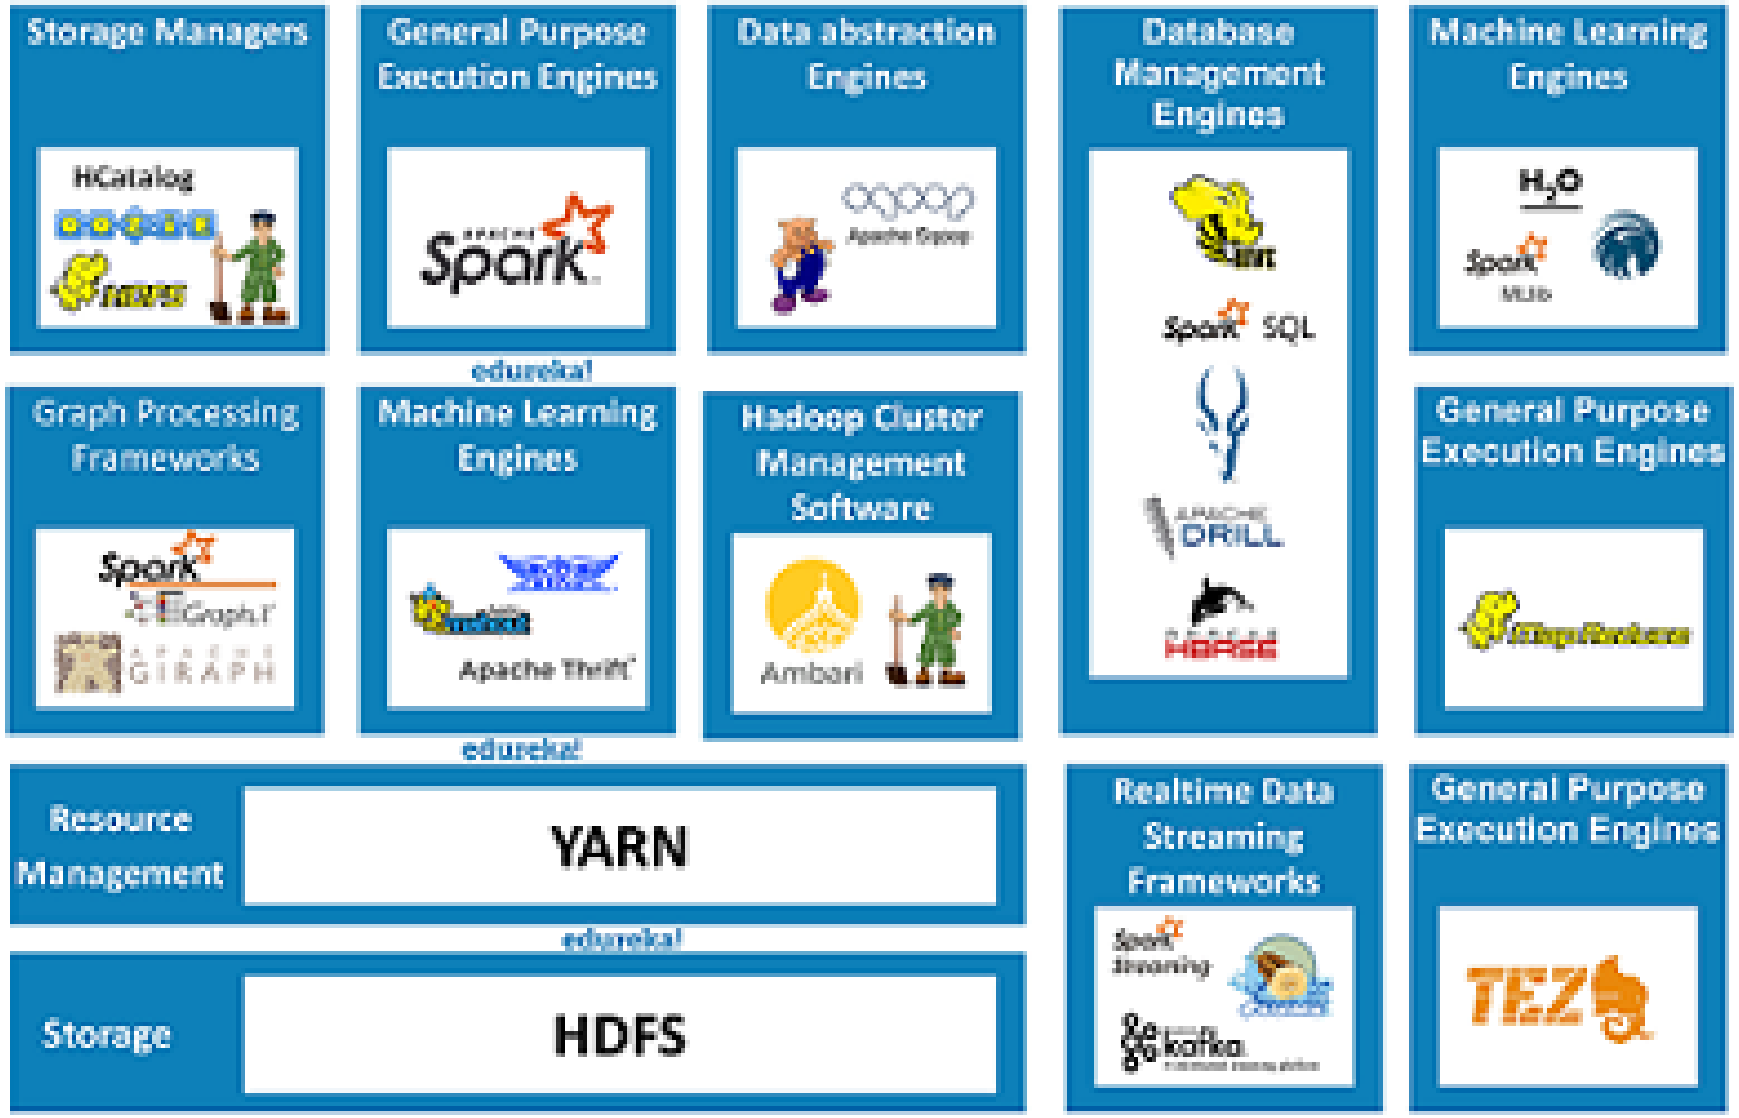
- **Trình quản lý tài nguyên (Resource Manager)**
  - Thành phần cốt lõi của YARN, được coi là Master.
  - Chịu trách nhiệm cung cấp các framework tổng quát và linh hoạt để quản lý tài nguyên tính toán trong một cụm Hadoop (Hadoop Cluster).
- **Trình quản lý nút (Node Manager)**
  - Nó là Slave và phục vụ cho Trình quản lý tài nguyên.
  - Trình quản lý nút được chỉ định cho tất cả các nút trong một cụm.
  - Trách nhiệm là giám sát trạng thái của Container và Trình quản lý ứng dụng.
    - Trình quản lý ứng dụng (App Manager): quản lý quá trình xử lý dữ liệu trong Container và yêu cầu tài nguyên Container từ Trình quản lý tài nguyên.
    - Container: là nơi diễn ra quá trình xử lý dữ liệu thực tế.

4. Hệ sinh thái Hadoop

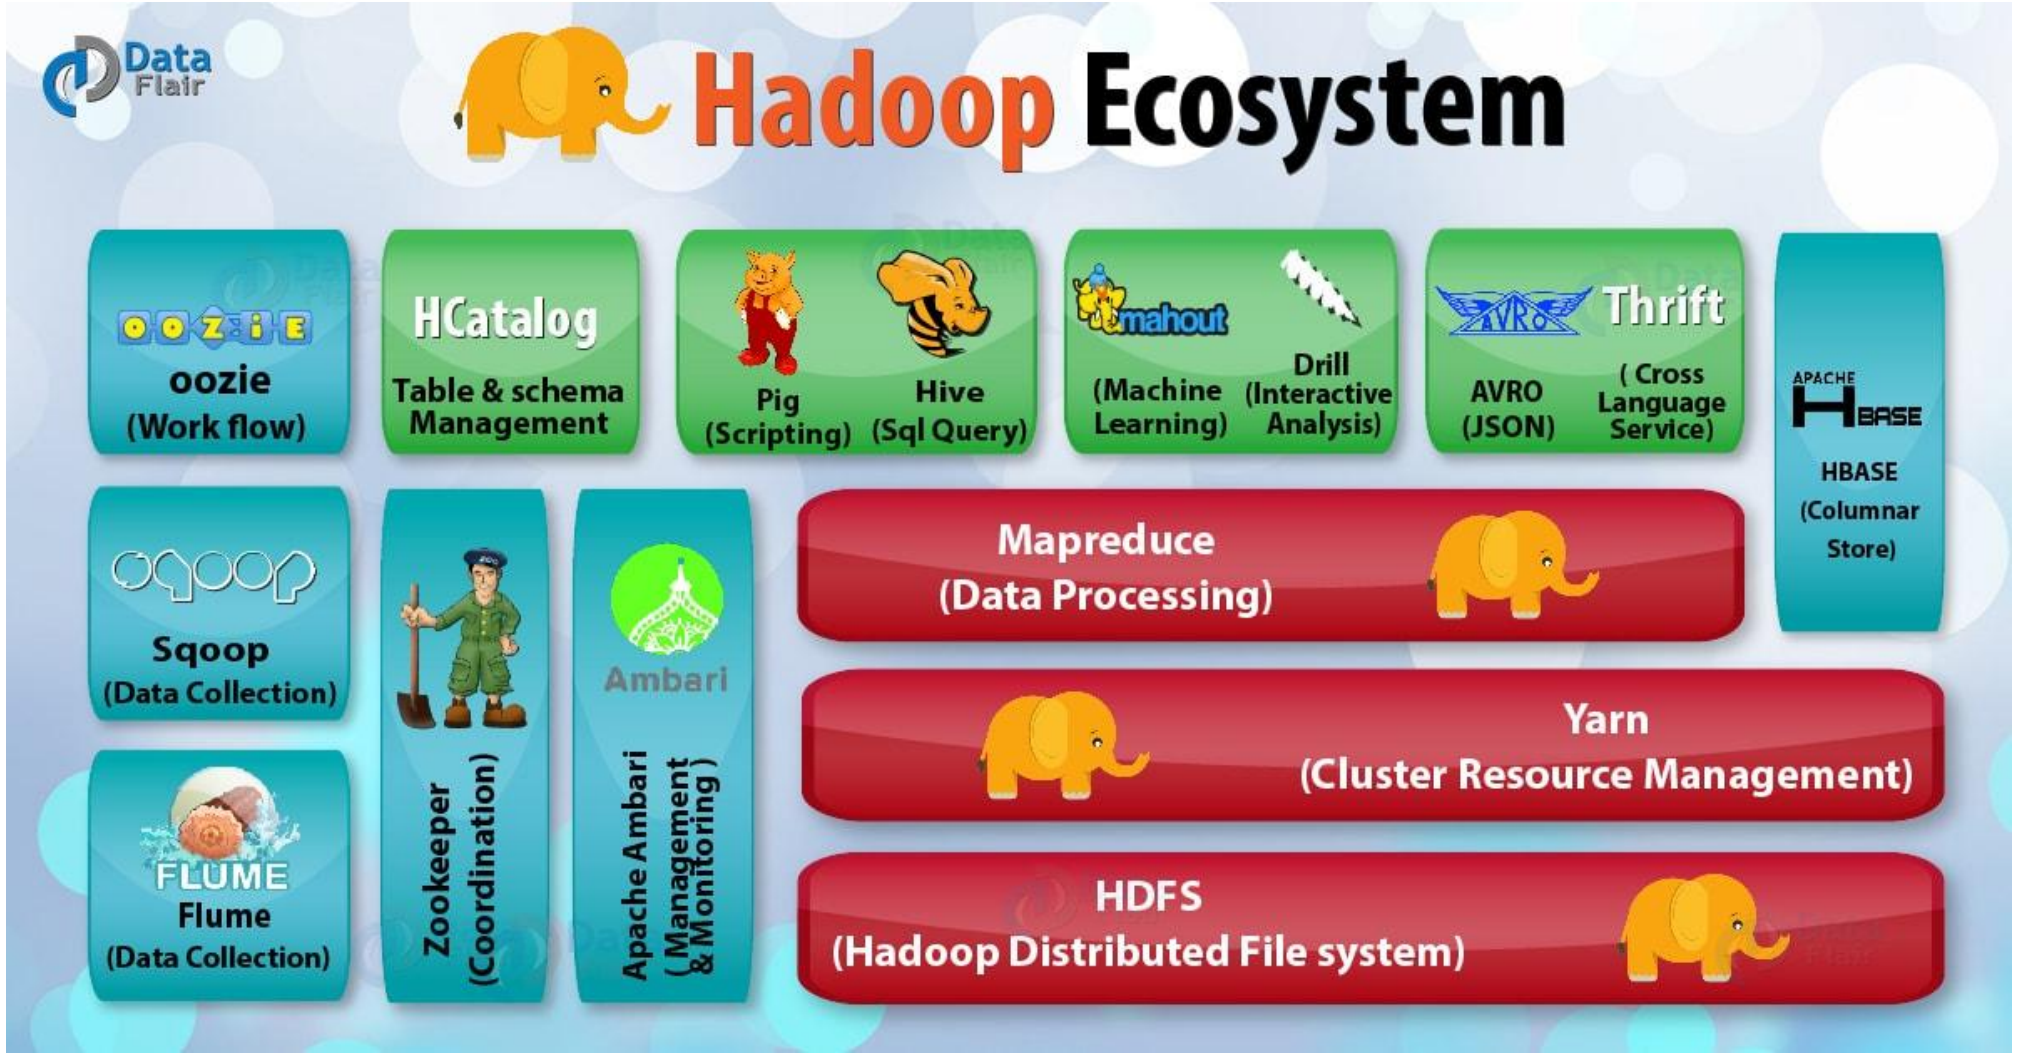
- Lưu trữ dữ liệu
- Các công cụ thực thi đa năng
- Công cụ quản trị cơ sở dữ liệu
- Các công cụ trừu tượng hóa dữ liệu
- Truyền dữ liệu thời gian thực
- Các công cụ xử lý đồ thị
- Học máy
- Quản trị cụm máy tính



Hình 7: Hệ sinh thái Hadoop



Hình 8: Hệ sinh thái Hadoop



Hình 9: Hệ sinh thái Hadoop

5. Tổng kết

1. Giới thiệu Apache Hadoop
2. Các thành phần chính của Apache Hadoop
3. Hệ sinh thái Hadoop

8. Bài tập

1. Bài tập cá nhân
   - Tìm hiểu các chức năng của các thành phần trong hệ sinh thái Hadoop (https://www.geeksforgeeks.org/dbms/hadoop-ecosystem/)
   - Cài đặt Hadoop Single Node
2. Bài tập nhóm (thuyết trình)
   - Tìm hiểu hoạt động của mô hình MapReduce (http://research.google.com/archive/mapreduce.html)



Trung tâm Học liệu và Dạy học số

Đại học Công nghệ Kỹ thuật Tp. Hồ Chí Minh

01 Võ Văn Ngân, P. Thủ Đức, Tp.Hồ Chí Minh

daotaotuxa@hcmute.edu.vn